

Econometría ICS-294

Clase 4: Variables omitidas

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Sesgo de selección y MCO

- Supongamos que tenemos el siguiente modelo lineal donde nos interesa el efecto de x_i en y_i .

$$y_i = \alpha + \beta x_i + \varepsilon_i$$

- El supuesto clásico crucial de MCO para que β sea el efecto causal (no haya sesgo de selección) es que:

$$E[\varepsilon \mid x] = 0$$

- Es decir, que todo lo que esta en el error no correlaciona con x .
- Si esto no se cumple, nuestro coeficiente estará sesgado.



Sesgo por Variables omitidas

- ¿Qué pasa si omitimos una variable que afecta a x ?
- ¿En términos de grupo tratamiento y control, que pasa si omitimos una variable que determina si el individuo es tratado o no?
- En este caso, no se cumple que $E[\epsilon | x] = 0$ y vamos a tener sesgo de selección.
- Ejemplo: quiero estudiar el efecto de la consultoría en la productividad de la empresa. Sea x_i una variable binaria que toma valor 1 si la empresa recibió asesoramiento por la consultora.

$$\text{productividad}_i = \alpha + \beta \cdot x_i + \epsilon_i$$

- es el $\hat{\beta}$ estimado por OLS el efecto causal? Qué variables estoy omitiendo?
- Podemos pensar que en el error está el tamaño de la empresa. Solo empresas más grandes pueden pagar por consultoría. Es decir, el tamaño correlaciona positivamente con la x . Al estar en el error, nuestro $\hat{\beta}$ MCO estará sesgado.



Omitiendo variables

- Suponga que la población sigue la siguiente ecuación (verdadera),

$$y = \alpha + \beta_1 x_1 + \beta_2 x_2 + u \quad (A)$$

donde $E[u \mid x] = 0$.

- (auxiliar) Además, supongan que sabemos que x_2 esta relacionada con x_1 de la siguiente manera:

$$x_2 = \delta_0 + \delta_1 x_1 + v \quad (B)$$

- Supongamos que como no observamos x_2 , estimamos el modelo MCO omitiendola (mandandola al error):

$$y = \tilde{\alpha} + x_1 \tilde{\beta}_1 + \epsilon \quad (C)$$

- ¿Qué supuesto no se cumpliría en este caso?
- Noten que comparando con (A), sabemos que $\epsilon = \beta_2 x_2 + u$. Por (B), sabemos que x_1 correlaciona con x_2 , entonces no se cumple $E[\epsilon \mid x_1] = 0$.
- Entonces, ¿qué esta capturando $\tilde{\beta}_1$?



Omitiendo variables

- Reemplazando (B) en (A):

$$y = \alpha + x_1\beta_1 + \beta_2(\delta_0 + \delta_1x_1 + v) + u$$

- Reordenando:

$$y = (\alpha + \beta_2\delta_0) + x_1(\beta_1 + \beta_2\delta_1) + (u + \beta_2v)$$




- Es decir, que cuando omitimos una variable y estimamos un modelo como (C). El coeficiente que estimamos es:

$$\tilde{\beta}_1 = \beta_1 + \beta_2\delta_1$$

- Entonces, capturamos el efecto causal (β_1) y un sesgo dado por $\beta_2\delta_1$.
- ¿De qué depende el sesgo? ¿Cuándo es 0?



Sesgo por omisión de variable



- Cuando una variable omitida provocará un sesgo entonces?

$$\tilde{\beta}_1 = \beta_1 + \beta_2\delta_1$$

- Solo en el caso (3) tenemos sesgo. Cuando omitimos una variable que afecta a X y a Y al mismo tiempo (en general lo segundo siempre pasa).
- Ejemplo:
 X_1 : educacion, Y = salario,
 x_2 : Inteligencia. En ese caso, $\beta_2 > 0$, $\delta_1 > 0$.
Por lo que $\tilde{\beta}_1$ sobre-estimaré el verdadero valor del parámetro.



Sesgo por omisión de variable

$$\tilde{\beta}_1 = \beta_1 + \beta_2 \delta_1$$

- Pensando en los signos de β_2 (como afecta la omitida a y) y δ_1 (como afecta la omitida a x_1), podemos comprender la dirección del sesgo. (los ejemplos con regresión de educación y salario)
 1. Si $\delta_1 > 0, \beta_2 > 0$: Sesgo positivo. Ejemplo omitida: Inteligencia.
 2. Si $\delta_1 < 0, \beta_2 < 0$: Sesgo positivo.
 3. $\delta_1 < 0, \beta_2 > 0$: Sesgo negativo.
 4. $\delta_1 > 0, \beta_2 < 0$: Sesgo negativo.
- La intuición es fácil. Piensen el caso (1). La gente mas inteligente va más a la universidad ($\delta_1 > 0$) y, además, la inteligencia mejora tu salario ($\beta_2 > 0$). Entonces, al omitir inteligencia, el coeficiente de educación se captura no solo el efecto causal sino también el hecho de que gente mas inteligente va más a la universidad y esa gente gana más (sin importar el efecto de la educación en si misma).



Soluciones a variables omitidas: Controles

- Cuál es la manera más obvia de solucionar el problema anterior?
- Si tengo la variable x_2 , la puedo incluir como control en la regresión y soluciono el problema.
- Vuelvo al caso en que $E[u \mid \mathbf{x}] = 0$ porque ahora estoy dejando ceteris paribus x_2 .
- En este caso, resuelve el problema porque conozco exacto el modelo verdadero y se que solo omitía x_2 . Sin embargo, muchas veces no alcanza porque hay otras variables omitidas.



Ejemplo 1

- Appleton, French and Vanderpump (1996): relación entre consumo de cigarrillos y muerte.

```
. reg y smoke
```

Source	SS	df	MS	Number of obs = 100			
Model	7613.25147	1	7613.25147	F(1, 98) = 194.34			
Residual	3839.18734	98	39.1753811	Prob > F = 0.0000			
Total	11452.4388	99	115.6812	R-squared = 0.6648			
				Adj R-squared = 0.6614			
				Root MSE = 6.259			

y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
smoke	-1.819348	.1305081	-13.94	0.000	-2.078337	-1.560359
_cons	158.5975	4.774249	33.22	0.000	149.1231	168.0718

- $\hat{\beta}_1 = -1,81$
- ¿Qué variables estamos omitiendo aca?



Ejemplo 2

- ¿Y si agregamos edad?

```
. reg y smoke age
```

Source	SS	df	MS	Number of obs = 100		
Model	11350.9524	2	5675.47622	F(2, 97) = 5424.58		
Residual	101.486373	97	1.04625126	Prob > F = 0.0000		
Total	11452.4388	99	115.6812	R-squared = 0.9911		
				Adj R-squared = 0.9910		
				Root MSE = 1.0229		

y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
smoke	.9431267	.050902	18.53	0.000	.8421004	1.044153
age	.9804631	.0164039	59.77	0.000	.9479059	1.01302
_cons	12.84084	2.560392	5.02	0.000	7.759169	17.92251

- Si este fuera el modelo verdadero, $\hat{\beta}_1 = 0,94 > \hat{\beta}_1 = -1,81$. Si $\hat{\beta}_2 > 0$, ¿qué me dice esto sobre el signo de relación entre edad y fumar cigarrillos δ_2 ?
- Recuerden: $\tilde{\beta}_1 = \beta_1 + \beta_2 \delta_2$
- Es negativa: cuanto mayor es la persona, menos fuma.



¿Más es mejor?

- Uno podría pensar que tiene que agregar todas las variables posibles al modelo, para evitar omitir variables.
- Sin embargo, esto trae problemas.
- Se dice que un modelo está sobre-especificado cuando se incluye en la regresión variables que no forman parte del modelo poblacional.
- Incluir variables irrelevantes en el modelo no influye en el insesgamiento de los estimadores, pero incrementa la varianza de los estimadores.



Sin sesgo de selección

- Si tenemos la suerte de tener una aleatorización que nos garantiza que no haya sesgo de selección, ¿importa agregar variables adicionales?
- Si X_1 (o T_i en términos de tratamiento) se determina de forma aleatoria, nos garantiza que $E[\epsilon_i | X_i] = 0$
- ¡La correlación entre cualquier variable no incluida en el modelo y el tratamiento será 0!
- Entonces, no necesitamos incluir otras variables en el modelo para evitar sesgos.



Conclusiones

- Incluir variables a un modelo cambia la interpretación de nuestra variable de interés.
- El impacto de la exclusión de una variable relevante depende de la correlación entre la variable de interés y la variable omitida y la relación entre la variable omitida y el outcome.
- El supuesto clave de MCO para que no haya sesgo es que $E[\epsilon \mid X] = 0$.
- Es poco frecuente que tengamos TODAS las variables que determinan la asignación y entonces, es poco probable que la inclusión de variables nos permita dar una interpretación causal a una regresión lineal.



Ejercicio final

- Queremos estimar el efecto causal de asistir a preuniversitario sobre el puntaje PSU:

$$puntaje_i = \alpha + \beta_1 preu_i + u_i$$

donde $preu_i = 1$ si el estudiante asistió a preuniversitario.

- La variable omitida es el apoyo familiar, $apoyo_i$, que afecta el puntaje y también la probabilidad de asistir a preuniversitario.
- Suponga que el modelo verdadero es:

$$puntaje_i = \alpha + \beta_1 preu_i + \beta_2 apoyo_i + u_i$$

y que:

$$apoyo_i = \delta_0 + \delta_1 preu_i + v_i$$

- Si $\beta_1 = 25$, $\beta_2 = 40$ y $\delta_1 = 0,5$, responda:
 1. ¿Cuál es el sesgo por variable omitida?
 2. ¿Cuál será el coeficiente estimado al omitir $apoyo_i$?
 3. ¿Se sobreestima o subestima el efecto causal del preuniversitario?



Solución ejercicio final

- La fórmula del coeficiente estimado cuando omitimos $apoyo_i$ es:

$$\tilde{\beta}_1 = \beta_1 + \beta_2 \delta_1$$

- Entonces, el sesgo es:

$$\beta_2 \delta_1 = 40 \cdot 0,5 = 20$$

- Por lo tanto:

$$\tilde{\beta}_1 = 25 + 20 = 45$$

- La regresión simple estimaría que asistir a preuniversitario aumenta el puntaje en 45 puntos.
- Pero el efecto causal verdadero era 25 puntos. Entonces, el efecto está **sobreestimado**.
- Intuición: estudiantes con más apoyo familiar tienden a asistir más al preuniversitario y, además, ese apoyo aumenta su puntaje. Al omitirlo, parte del efecto del apoyo familiar se atribuye erróneamente al preuniversitario.

