

Econometría ICS-294

Clase 5: Error de medición

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



El mundo real

- Cuando tratamos de estimar la relación entre variables, hay que usar lo que está disponible en los datos reales.
- A menudo, no se cuenta con datos sobre la variable económica que realmente nos interesa.
- Ejemplo
 - Ingreso verdadero vs. ingreso declarado
 - Calorías consumidas vs. calorías compradas



Error de Medición

- La variable que nos interesa es W^* , pero solo tenemos una versión imprecisa de esta variable donde:

$$W = W^* + u$$

- Se define como “error de medida” $u = W - W^*$. Es decir, la diferencia entre la variable que observamos y la verdadera variable.
- Supongamos el error menos grave posible. Lo llamamos error clásico cuando $E(u) = 0$ y $\text{Cov}(u, W^*) = 0$.
- ¿Qué pasa si tenemos errores de medición clásico en la variable dependiente?
¿E independiente?



Error de medición en la variable dependiente

- Considere el siguiente modelo verdadero, no hay sesgo por variable omitida:

$$Y^* = \beta_0 + \beta_1 X + \varepsilon \quad (1)$$

$$E[\varepsilon | X] = 0$$

- Pero en lugar de Y^* solamente tenemos $Y = Y^* + u$. Donde el error de medición lo asumimos clásico: $\text{Cov}(Y^*, u) = 0$ y $V(u) = \sigma_u^2$.
- Si sustituimos $Y - u = Y^*$ en (1) y despejamos, podemos estimar:

$$Y = \beta_0 + \beta_1 X + v \quad (2)$$

- Donde $v = (\varepsilon + u)$
- ¿Será $\hat{\beta}_1$ insesgado?
- Como suponemos que el error de medición de la variable Y **no** esta correlacionado con X , entonces no causará sesgo.



Error de medición en la variable dependiente

- Para que los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ sean insesgados, necesitamos que

$$E(\hat{\beta}_1) = \beta_1$$

- Sabemos que

$$E(\hat{\beta}_1) = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\text{Cov}(X, Y^* + u)}{\text{Var}(X)}$$

$$E(\hat{\beta}_1) = \frac{\text{Cov}(X, Y^*)}{\text{Var}(X)} + \frac{\text{Cov}(X, u)}{\text{Var}(X)}$$

$$E(\hat{\beta}_1) = \beta_1$$

- Dado que $\text{Cov}(X, u) = 0$ por la definición del error clásico.



Intuición

Si el error de medida en la variable dependiente no está sistemáticamente relacionado con las variables explicativas, entonces el estimador MCO sigue siendo insesgado.




Impacto sobre precisión

- Sin embargo, los estimadores de MCO van a tener mayores varianza
- Con errores de medición en la variable dependiente, el término del error es $\varepsilon + u$. Y entonces, su varianza es $\text{Var}(\varepsilon) + \text{Var}(u) > \text{Var}(\varepsilon)$.



Ejemplo: Relación entre salario e IQ



Errores de medición en variables independientes

- Cuando la variable mal medida es la independiente, el problema es más grave.
- La variable que nos interesa es X^* , pero solo tenemos una versión imprecisa de esta variable donde

$$X = X^* + u$$

- Vamos a seguir suponiendo errores clásicos, es decir que $\text{Cov}(X^*, u) = 0$ y $V(u) = \sigma_u^2$.



Impacto sobre MCO

- El modelo verdadero es:

$$Y = \beta_0 + \beta_1 X^* + \epsilon \quad (1)$$

- Donde asumimos que $E[\epsilon | X^*] = 0$

- Pero podemos estimar:

$$Y = b_0 + b_1 X + v \quad (2)$$

- $v = \epsilon - \beta_1 u$
- Vamos a ver que ahora el estimador $\hat{b}_1$ va a ser sesgado.



Sesgo de atenuación - sesgo por error de medición en X

- Estimamos:

$$Y = b_0 + b_1 X + v$$

$$E[\hat{b}_1] = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\text{Cov}(X^* + u, Y)}{\text{Var}(X^* + u)}$$

- Dado que el error es clásico: $\text{Cov}(u, Y) = 0$ por lo que:

$$E[\hat{b}_1] = \frac{\text{Cov}(X^*, Y)}{\text{Var}(X^* + u)}$$

- Además, el denominador lo podemos escribir como la suma de varianzas:

$$\text{Var}(X^* + u) = \text{Var}(X^*) + \text{Var}(u)$$

- Reemplazando Y por el modelo original (1):

$$E[\hat{b}_1] = \frac{\text{Cov}(X^*, \beta_0 + \beta_1 X^* + \epsilon)}{\text{Var}(X^*) + \text{Var}(u)}$$



- separando las covarianzas:

$$E \left[\hat{b}_1 \right] = \frac{\beta_1 \text{Cov} (X^*, X^*) + \text{Cov} (X^*, \epsilon)}{\text{Var} (X^*) + \text{Var}(u)}$$

- Sabemos que el modelo real esta bien especificado por lo que $\text{Cov} (X^*, \epsilon) = 0$. Además, por definición, $\text{Cov} (X^*, X^*) = \text{Var} (X^*)$.

- Entonces:

$$E \left(\hat{b}_1 \right) = \beta_1 \frac{\text{Var} (X^*)}{\text{Var} (X^*) + \text{Var}(u)} = a \cdot \beta_1$$

- Noten que $a < 1$.
- Por eso se llama sesgo de atenuación. El coeficiente de MCO será más pequeño en valor absoluto, subestimaremos el efecto.



Sesgo de atenuación

$$E(\hat{b}_1) = \beta_1 \frac{\text{Var}(X^*)}{\text{Var}(X^*) + \text{Var}(u)} = a \cdot \beta_1$$

- Si $\beta_1 > 0$, el estimador será menor al parámetro.
- Si $\beta_1 < 0$, el estimador será mayor al parámetro, menor en valor absoluto.
- Entonces, tendremos a subestimar (en valor absoluto) la magnitud de la pendiente.
- La magnitud del sesgo depende de cuan grande es $\text{Var}(u)$ comparado a $\text{Var}(X)$. Esto se llama: "signal-to-noise ratio".



Ejemplo simple: horas de estudio y nota

- Supongamos que el modelo verdadero es:

$$Nota = \beta_0 + 2 \cdot Horas^* + \epsilon$$

- Es decir, una hora adicional de estudio real aumenta la nota esperada en 2 puntos.
- Pero no observamos las horas reales $Horas^*$, sino un reporte con error:

$$Horas = Horas^* + u$$

- Supongamos que:

$$\text{Var}(Horas^*) = 8 \quad \text{y} \quad \text{Var}(u) = 2$$



Ejemplo simple: sesgo de atenuación

- Si estimamos usando $Horas$ en lugar de $Horas^*$:

$$E(\hat{b}_1) = 2 \cdot \frac{8}{8+2} = 1,6$$

- Aunque el efecto verdadero es $\beta_1 = 2$, MCO estima en promedio una pendiente menor.
- Intuición: el ruido en $Horas$ aumenta la variabilidad de la variable explicativa, pero no agrega información sobre $Nota$.
- Por eso el coeficiente se “achica” hacia cero.



Conclusiones

- Cuando trabajamos con datos reales, no siempre medimos exactamente lo que queremos en nuestro modelo.
- Errores de medición de la variable dependiente no generan sesgo pero si aumentan varianza, dificultando el reconocimiento de relaciones entre variables.
- El error de medición en variables independientes genera sesgo de atenuación: siempre vamos a subestimar la magnitud de la relación entre variables.

