

Econometría ICS-294

Clase 6: Estimación del Modelo de Regresión Lineal Múltiple

Francisco Alfaro Medina

Universidad Técnica Federico Santa María

Modelo de Regresión Múltiple: Introducción

- ▶ En las clases anteriores, vimos el modelo de regresión lineal simple:

$$y = \beta_0 + \beta_1 x + u$$

- ▶ Sin embargo, el supuesto de que $E[u|x] = 0$ en dicho modelo es muy fuerte, ya que todas las variables no incluidas van al error.
- ▶ Además, si nos interesa la predicción, es muy difícil predecir la variable y en base a una sola variable.
- ▶ El modelo de regresión lineal múltiple (RLM) permite esto.

Modelo de Regresión Lineal Múltiple

- ▶ A nivel poblacional, el modelo RLM se define como:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

- ▶ Asumamos que $E[u|x_1, x_2, \dots, x_k] = 0$.
- ▶ Interpretación de los parámetros β :
- ▶ Por ejemplo, si todas las variables excepto x_1 permanecen constantes:

$$\Delta E[y|x_1, x_2, \dots, x_k] = \beta_1 \Delta x_1$$

$$\Rightarrow \beta_1 = \frac{\Delta E[y|x_1, x_2, \dots, x_k]}{\Delta x_1}$$

- ▶ Interpretación: Cuando x_1 cambia en una unidad, el valor esperado de y cambia en β_1 unidades, **manteniendo todas las demás variables incluidas constantes**.

Es como una derivada parcial!

Modelo de Regresión Múltiple: Estimación MCO

- ▶ Al agregar más variables al modelo para poder estudiar el efecto de x , ceteris paribus estas otras variables.
- ▶ Por ejemplo, al estudiar el efecto de educación en salario, queremos dejar la inteligencia constante (IQ).
- ▶ Al incluir esta variable en la regresión, podemos ver cuánto afecta un año más de educación en salario, dejando constante IQ.
- ▶ De hecho, si agregamos la variable IQ, el coeficiente de educación que obtenemos se hace más pequeño.

$$\text{MCO Simple: } \hat{\text{salario}} = 0,09 + 0,54 \cdot \text{educacion}$$

$$\text{MCO Múltiple: } \hat{\text{salario}} = 0,065 + 0,37 \cdot \text{educacion} + 0,20 \cdot \text{IQ}$$

- ▶ Ahora vamos a ver cómo estimar los $\hat{\beta}$ del modelo de regresión múltiple.

Modelo de Regresión Lineal Múltiple: Estimación

Dada una muestra de n individuos, tenemos la siguiente ecuación:

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik} + \hat{u}_i, \quad \forall i = 1, \dots, n$$

Igual que en el modelo RLS, los **residuos** vienen dados por:

$$\hat{u}_i = y_i - \hat{y}_i$$

$$\hat{u}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik})$$

MCO para el Modelo Lineal Múltiple

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} \sum_i \hat{u}_i^2$$

Es decir,

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} \sum_i \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right)^2$$

CPO:

$$\hat{\beta}_0 : \sum_i \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right) = 0$$

$$\hat{\beta}_1 : \sum_i x_{i1} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right) = 0$$

...

$$\hat{\beta}_k : \sum_i x_{ik} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right) = 0$$

Existen $k + 1$ condiciones de primer orden para $k + 1$ incógnitas.

Notación matricial modelo poblacional

- ▶ El modelo de regresión lineal múltiple cada individuo i es:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + u_i \quad \forall i = 1, \dots, n$$

- ▶ Matricialmente, lo podemos expresar:

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + u_i \quad \forall i = 1, \dots, n$$

con

$$\mathbf{x}_i = \begin{pmatrix} 1 \\ x_{i1} \\ \vdots \\ x_{ik} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

- ▶ Noten que son n ecuaciones (una para cada individuo).

Notación



$$y = X\beta + u$$

con

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix}, \quad u = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}$$

donde u y y son vectores de $n \times 1$ y X es una matriz de $n \times (k + 1)$.

Ejemplo: $n = 5$, dos variables: x_1, x_2

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_5 \end{bmatrix} = \beta_0 \begin{bmatrix} 1 \\ 1 \\ \dots \\ 1 \end{bmatrix} + \beta_1 \begin{bmatrix} x_{11} \\ x_{12} \\ \dots \\ x_{15} \end{bmatrix} + \beta_2 \begin{bmatrix} x_{21} \\ x_{22} \\ \dots \\ x_{25} \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \dots \\ u_5 \end{bmatrix}$$

Re-escribiendo:

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_5 \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{12} & x_{22} \\ \dots & \dots & \dots \\ 1 & x_{15} & x_{25} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \dots \\ u_5 \end{bmatrix}$$

$$y = X\beta + u$$

Mínimos Cuadrados Ordinarios (MRL Múltiple)

- ▶ Como antes, podemos definir:
 - ▶ $\hat{\beta}$: estimadores de los β dimensión, $(k + 1) \times 1$
 - ▶ $\hat{y} = X\hat{\beta}$: Valores predichos de y , dimensión $n \times 1$
 - ▶ Por lo tanto, los residuos en forma matricial:

$$\hat{u} = y - \hat{y} = y - X\hat{\beta}$$

Recordar

► Derivadas

Si a y β son vectores y A una matriz simétrica, entonces:

1. $\frac{da^\top \beta}{d\beta} = a$

2. $\frac{d\beta^\top A \beta}{d\beta} = 2A\beta$

► Propiedades de la traspuesta

Sean D y E matrices: $(DE)^\top = E^\top D^\top$

► Potencias

$$\sum_i (s_i)^2 = s^\top s$$

Mínimos Cuadrados Ordinarios (MRL Múltiple)

$$\min \sum_{i=1}^n \hat{u}_i^2 \Rightarrow \min_{\hat{\beta}} \hat{u}^\top \hat{u}$$

- La suma de los residuos al cuadrado es:

$$\begin{aligned}\hat{u}^\top \hat{u} &= (y - X\hat{\beta})^\top (y - X\hat{\beta}) \\ &= y^\top y - \hat{\beta}^\top X^\top y - y^\top X\hat{\beta} + \hat{\beta}^\top X^\top X\hat{\beta} \\ &= y^\top y - 2y^\top X\hat{\beta} + \hat{\beta}^\top X^\top X\hat{\beta}\end{aligned}$$

- Entonces, condiciones de primer orden:

$$\frac{\partial \hat{u}^\top \hat{u}}{\partial \hat{\beta}} = 0 \Rightarrow -2X^\top y + 2X^\top X\hat{\beta} = 0 \Rightarrow \hat{\beta} = (X^\top X)^{-1} X^\top y$$

- Note que precisamos suponer que X tiene rango $(k+1)$ completo $\Rightarrow X^\top X$ es invertible.
- Las $k+1$ ecuaciones $X^\top y = X^\top X\hat{\beta}$ son llamadas ecuaciones normales para MCO.
- Condición de segundo grado: $\frac{d^2 \hat{u}^\top \hat{u}}{d\hat{\beta} d\hat{\beta}} = 2X^\top X$ positiva definida.

Propiedades algebraicas

- ▶ Al igual que el caso de regresión simple, las propiedades algebraicas se derivan de las CPO.
- ▶ Propiedades 1 y 2: $X^\top \hat{u} = 0$:

$$\sum_i \hat{u}_i = 0 \quad (\text{propiedad 1})$$

$$\sum_i x_{i1} \hat{u}_i = 0 \quad (\text{propiedad 2})$$

$$\sum_i x_{i2} \hat{u}_i = 0 \quad (\text{propiedad 2})$$

...

$$\sum_i x_{ik} \hat{u}_i = 0 \quad (\text{propiedad 2})$$

- ▶ Propiedad 3: La media de la variable observada y es igual a la media de la variable predicha $\hat{y}$:

$$\bar{y} = \bar{\hat{y}}$$

- ▶ Propiedad 4: El punto $(\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k, \bar{y})$ pasa por la curva de regresión.

Bondad de Ajuste: R^2

El R^2 nos dice que la proporción de la varianza muestral de y es explicada por nuestra regresión MCO. Recordando las definiciones:

- ▶ Suma de cuadrados explicada: $SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- ▶ Suma de cuadrados residual: $SSR = \sum_{i=1}^n \hat{u}_i^2$
- ▶ Suma de cuadrados total: $SST = \sum_{i=1}^n (y_i - \bar{y})^2$

La fórmula para el R^2 es igual que en el caso de la regresión simple:

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

Bondad de Ajuste: R^2 ajustado

- ▶ R^2 crece (o queda igual) a medida que se agregan más variables al modelo. Esto ocurre incluso si la variable agregada no es relevante en el modelo poblacional.
- ▶ Necesitamos una medida que penalice agregar variables irrelevantes.
- ▶ Se define el R^2 ajustado como:

$$\overline{R^2} = 1 - \frac{n-1}{n-k-1} \frac{SSR}{SST}$$

Ejercicio de cierre

Considere el modelo estimado:

$$\widehat{\text{salario}} = 120 + 35 \text{educ} + 8 \text{exper}$$

1. Interprete el coeficiente de *educ*.
2. Calcule el salario predicho para una persona con 12 años de educación y 5 años de experiencia.
3. Si $SSR = 1800$, $SST = 6000$, $n = 40$ y $k = 2$, calcule R^2 y $\overline{R^2}$.

Respuesta: $R^2 = 1 - \frac{1800}{6000} = 0,70$ y

$$\overline{R^2} = 1 - \frac{39}{37} \frac{1800}{6000} \approx 0,684.$$

Conclusiones

- ▶ El modelo de regresión múltiple permite estudiar efectos parciales, manteniendo constantes las demás variables incluidas.
- ▶ La estimación MCO puede escribirse en forma matricial como $\hat{\beta} = (X^T X)^{-1} X^T y$, siempre que $X^T X$ sea invertible.
- ▶ Las propiedades algebraicas de MCO permiten definir medidas de ajuste como R^2 y R^2 ajustado.
- ▶ El R^2 ajustado es útil para comparar modelos con distinto número de regresores.