

Clase 7: Propiedades estadísticas del estimador MCO

Universidad Técnica Federico Santa María



Resumen clase anterior

- ▶ Vimos la forma matricial del modelo de regresión lineal múltiple: $y = X\beta + u$
- ▶ Demostramos que por MCO se puede obtener: $\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = (X^\top X)^{-1} X^\top y$

Interpretación $\hat{\beta}_1$: Cuando cambia x_1 en una unidad, en promedio y cambia $\hat{\beta}_1$ unidades, manteniendo todas las demás x constantes.

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Modelo: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$, $n = 5$.

Base de datos:

Individuos	unos	x_1 (experiencia)	x_2 (educación)	y (salario)
Juan	1	12	93	769
Pedro	1	18	119	808
Sofia	1	14	108	825
Caro	1	12	96	650
Alex	1	11	74	562

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Modelo: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$, $n = 5$.

Base de datos:

Individuos	unos	x_1 (experiencia)	x_2 (educación)	y (salario)
Juan	1	12	93	769
Pedro	1	18	119	808
Sofia	1	14	108	825
Caro	1	12	96	650
Alex	1	11	74	562

$$X = \begin{bmatrix} 1 & 12 & 93 \\ 1 & 18 & 119 \\ 1 & 14 & 108 \\ 1 & 12 & 96 \\ 1 & 11 & 74 \end{bmatrix} \quad X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix}$$

$$X^T X = \begin{bmatrix} 5 & 67 & 490 \\ 67 & 929 & 6736 \\ 490 & 6736 & 49166 \end{bmatrix}$$

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Modelo: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$, $n = 5$.

Base de datos:

Individuos	unos	x_1 (experiencia)	x_2 (educación)	y (salario)
Juan	1	12	93	769
Pedro	1	18	119	808
Sofia	1	14	108	825
Caro	1	12	96	650
Alex	1	11	74	562

$$X = \begin{bmatrix} 1 & 12 & 93 \\ 1 & 18 & 119 \\ 1 & 14 & 108 \\ 1 & 12 & 96 \\ 1 & 11 & 74 \end{bmatrix} \quad X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix}$$

$$X^T X = \begin{bmatrix} 5 & 67 & 490 \\ 67 & 929 & 6736 \\ 490 & 6736 & 49166 \end{bmatrix} \quad (X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$$

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

$$X^T y = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix} \times \begin{bmatrix} 769 \\ 808 \\ 825 \\ 650 \\ 562 \end{bmatrix} = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

$$X^T y = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix} \times \begin{bmatrix} 769 \\ 808 \\ 825 \\ 650 \\ 562 \end{bmatrix} = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix} =$$

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Entonces tenemos: $(X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$

$$X^T y = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Entonces tenemos: $(X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$

$$X^T y = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$

Multiplicando obtenemos los estimadores:

$$\hat{\beta} = (X^T X)^{-1} X^T y = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 140,59 \\ -16,79 \\ 8,24 \end{bmatrix}$$

Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Entonces tenemos: $(X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$

$$X^T y = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$

Multiplicando obtenemos los estimadores:

$$\hat{\beta} = (X^T X)^{-1} X^T y = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 140,59 \\ -16,79 \\ 8,24 \end{bmatrix}$$

Si quisieramos la matrix de prediccion de y, simplemente calculamos:

$$\hat{y} = X \hat{\beta}$$

En general

$$X^T X = \begin{pmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} & \cdots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1}x_{i2} & \cdots & \sum_{i=1}^n x_{i1}x_{ik} \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i1}x_{i2} & \sum_{i=1}^n x_{i2}^2 & \cdots & \sum_{i=1}^n x_{i2}x_{ik} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{i1}x_{ik} & \sum_{i=1}^n x_{i2}x_{ik} & \cdots & \sum_{i=1}^n x_{ik}^2 \end{pmatrix}$$

$$X^T y = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1}y_i \\ \vdots \\ \sum_{i=1}^n x_{ik}y_i \end{pmatrix}$$

En R

```
experiencia <- c(12,18,14,12,11)
educacion<- c(93,119,108,96,74)
y_sal<-c(769,808,825,650,562)
unos<- c(1,1,1,1,1)
X <- cbind(unos,experiencia, educacion)
X_T<- t(X)

X_TX<- X_T%*%X
X_TX_inv<- solve(X_TX)
X_TY_sal<- X_T%*%y_sal
beta_hat<- X_TX_inv%*%X_TY_sal
Y_hat<- X%*%beta_hat
u_hat <- y_sal-Y_hat
```

Regresión

```
lm(formula = y_sal ~ experiencia + educacion)
```

Residuals:

1	2	3	4	5
63.878	-10.538	29.907	-79.832	-3.415

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	140.586	224.616	0.626	0.595
experiencia	-16.790	30.964	-0.542	0.642
educacion	8.237	5.109	1.612	0.248

Residual standard error: 75.73 on 2 degrees of freedom

Multiple R-squared: 0.7751, Adjusted R-squared: 0.5501

F-statistic: 3.446 on 2 and 2 DF, p-value: 0.2249

Supuestos Clásicos

¿ $\hat{\beta}$ es un buen estimador para β ? ¿Qué significa que sea bueno?

Supuestos clásicos:

1. Linealidad en parámetros
2. Muestra aleatoria
3. Condición de identificación
4. Ortogonalidad
5. Homocedasticidad

Supuesto 1: Linealidad en Parámetros

- ▶ La relación poblacional entre las variables sigue un modelo lineal:

$$y = X\beta + u \quad (1)$$

$$= \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u \quad (2)$$

donde $\beta_0, \beta_1, \dots, \beta_k$ son parámetros desconocidos y u es una variable no observable llamada término de error o perturbación.

- ▶ Si el modelo analítico no es lineal en los parámetros, hay que linealizarlo, en la medida de lo posible.
- ▶ Por ejemplo:

$$Y = AK^{\alpha_1} Q^{\alpha_2} L^{\alpha_3}$$

se lineariza como

$$\log Y = \log A + \alpha_1 \log K + \alpha_2 \log Q + \alpha_3 \log L$$

Supuesto 2: Muestra Aleatoria

- ▶ Las n observaciones provienen de una muestra aleatoria de la población,

$$\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i) : i = 1, 2, \dots, n\}$$

- ▶ Esto significa que las observaciones son independientes unas de otras, lo que implica que

$$\text{cov}(u_i, u_j | X) = 0 \quad \forall i \neq j$$

- ▶ En series de tiempo lo anterior implica que los errores no tienen autocorrelación.

Supuesto 3: Condición de Identificación (No multicolinealidad perfecta)

- ▶ X tiene rango columna completo $k + 1$.
- ▶ No hay relaciones lineales exactas entre las variables independientes.
- ▶ Esto implica:
 - ▶ Las columnas de X son linealmente independientes.
 - ▶ Existe la inversa de $X^T X$.
 - ▶ $n \geq k + 1$.

Ejemplo de violación a este supuesto: $x_2 = 2x_1$. La fila 2 es linealmente dependiente de la 1.

Supuesto 4: Ortogonalidad (Exogeneidad)

- ▶ $E[u|X] = E(u|x_1, x_2, \dots, x_k) = 0$.
- ▶ Esto implica que:
 - ▶ $E[X^\top u] = 0$: la covarianza entre las x y el error es cero.
 - ▶ $E(y|X) = E(X\beta + u|X) = X\beta$.

Vamos a ver que este supuesto va a ser el supuesto clave para interpretar causalmente los coeficientes.

Supuesto 4: Ortogonalidad (Exogeneidad)

- ▶ $E[u|X] = E(u|x_1, x_2, \dots, x_k) = 0$.
- ▶ Esto implica que:
 - ▶ $E[X^\top u] = 0$: la covarianza entre las x y el error es cero.
 - ▶ $E(y|X) = E(X\beta + u|X) = X\beta$.
- ▶ Vamos a ver que este supuesto va a ser el supuesto clave para interpretar causalmente los coeficientes.
- ▶ Este supuesto puede no cumplirse por varias razones:
 - ▶ Omisión de una variable que está correlacionada con alguna x .
 - ▶ Errores de medición en los regresores.
- ▶ Por desgracia, muy pocas veces se sabe con seguridad si el valor promedio de los factores no observables de hecho no está relacionado con las variables explicativas. **Pero este es el supuesto crítico.**

Supuesto 5: Homocedasticidad y no autocorrelación

- ▶ La varianza del error no depende de X :


$$\text{Var}(u_i|x_1, \dots, x_k) = E[u_i^2|x] = \sigma^2$$

- ▶ En caso de que el supuesto no se cumpla, se dice que el modelo presenta heterocedasticidad.
- ▶ Ejemplo donde no se cumpliría esta condición: si tenemos salario en función de años de escolaridad, la varianza de u es probablemente menor para escolaridades pequeñas.
- ▶ Con esto, la varianza condicional del vector u queda: $\text{Var}(u|X) = \sigma^2 I$.
- ▶ La covarianza de los errores es cero:


$$\text{Covar}(u_i, u_j|x_1, \dots, x_k) = 0$$

Supuesto 5: Homocedasticidad

- Homocedasticidad en un modelo simple (mismo σ).



- Heterocedasticidad en un modelo simple.



Resumen Supuestos

1. Linealidad en parámetros ($y = X\beta + u$).
2. Muestra aleatoria.
3. X tiene rango completo ($k + 1$), es decir, todas las variables son linealmente independientes.
4. Ortogonalidad: $E[u|X] = 0$.
5. Homocedasticidad y no-autocorrelación: $V(u|X) = \sigma^2 I$

Propiedades Estadísticas de los Estimadores $\hat{\beta}$

Bajo los supuestos clásicos, los estimadores MCO cumplen lo siguiente:

1. $\hat{\beta}$ es insesgado: $E(\hat{\beta}) = \beta$.
2. $V(\hat{\beta}|X) = (X^{\top}X)^{-1}\sigma^2$.
3. Teorema de Gauss-Markov: $\hat{\beta}$ es el estimador lineal insesgado de menor varianza (MELI-BLUE).

El Estimador MCO es Insesgado

- ▶ Teorema: Bajo los supuestos 1 a 4, el estimador MCO de β es insesgado.
- ▶ Demostración:

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (3)$$

$$= (X^T X)^{-1} X^T (X\beta + u) \quad (4)$$

$$= \beta + (X^T X)^{-1} X^T u \quad (5)$$

$$E(\hat{\beta}|X) = \beta + (X^T X)^{-1} X^T E(u|X) \quad (6)$$

$$= \beta \quad (7)$$

- ▶ Esto implica que el promedio de los estimadores $\hat{\beta}$ obtenidos con todas las muestras aleatorias posibles es igual a β .

Varianza del Estimador MCO

- Teorema: Bajo los supuestos 1 a 5, la varianza del estimador MCO de β es $\text{Var}(\hat{\beta}|X) = \sigma^2(X^\top X)^{-1}$.
- Demostración:

$$\text{Var}(\hat{\beta}|X) = E[(\hat{\beta} - E(\hat{\beta}))(\hat{\beta} - E(\hat{\beta}))^\top | X] \quad (8)$$

$$= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^\top | X] \quad (9)$$

$$= E[(X^\top X)^{-1} X^\top u u^\top X (X^\top X)^{-1} | X] \quad (10)$$

$$= (X^\top X)^{-1} X^\top E[u u^\top | X] X (X^\top X)^{-1} \quad (11)$$

$$= (X^\top X)^{-1} X^\top \sigma^2 I X (X^\top X)^{-1} \quad (12)$$

$$= \sigma^2 (X^\top X)^{-1} (X^\top X) (X^\top X)^{-1} \quad (13)$$

$$= \sigma^2 (X^\top X)^{-1} \quad (14)$$

- nota: $\hat{\beta} = \beta + (X^\top X)^{-1} X^\top u$

Ejercicio de cierre

Suponga que se estima el modelo:

$$\text{salario}_i = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_i + u_i$$

1. Si habilidad no observada afecta el salario y está correlacionada con *educ*, ¿qué supuesto clásico se viola?
2. Si $E[u|X] = 0$, ¿qué podemos decir sobre $E(\hat{\beta}|X)$?
3. Si además hay homocedasticidad, ¿cuál es la varianza de $\hat{\beta}$?

Respuesta: se viola exogeneidad. Si $E[u|X] = 0$, entonces $E(\hat{\beta}|X) = \beta$.
Con homocedasticidad,

$$\text{Var}(\hat{\beta}|X) = \sigma^2(X^\top X)^{-1}.$$

Conclusiones

- ▶ Los supuestos clásicos conectan el modelo poblacional con las propiedades estadísticas del estimador MCO.
- ▶ La exogeneidad es el supuesto central para interpretar los coeficientes como efectos causales.
- ▶ Bajo los supuestos 1 a 4, MCO es insesgado.
- ▶ Bajo los supuestos 1 a 5, la varianza condicional es $\sigma^2(X^\top X)^{-1}$.