

Econometría ICS-294

Clase 2: Modelo de Regresión Lineal Simple

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Modelo de regresión lineal simple

- ▶ Queremos estudiar la relación entre dos variables x e y en la población.
- ▶ Explicar y en terminos de x o como cambia y cuando cambia x .
- ▶ Modelo de regresión lineal simple (RLS):

$$y = \beta_0 + \beta_1 x + u \quad (1)$$

- ▶ β_0, β_1 son parámetros poblacionales.
- ▶ u : término de error o perturbación, factores no-observables que afectan a y .
- ▶ El coeficiente β_0 , permite suponer que $E(u) = 0$.
- ▶ β_1 captura como cambia y cuando cambia x .



Modelo de regresión lineal simple

$$y = \beta_0 + \beta_1 x + u \quad (2)$$

Terminología:

- ▶ y : variable dependiente, variable explicada, variable de respuesta, variable predicha o el regresando.
- ▶ x : variable independiente, variable explicativa, variable de control, variable predictora o el regresor.
- ▶ β_1 : es el parámetro de la pendiente en la relación entre y y x , cuando todos los demás factores en u permanecen constantes, este parámetro es de interés primordial en la economía aplicada.
- ▶ β_0 : es el parámetro del intercepto, algunas veces llamado término constante.



Termino de error

- ▶ La variable u , llamada **término de error**, o **perturbación** en la relación, representa factores distintos a x que afectan a y .
- ▶ Un análisis de regresión simple en realidad trata a todos los factores que afectan a y , y que son distintos a x como factores no observados.
- ▶ Es útil considerar a u como abreviación de “unobserved”.



Ejemplo

- ▶ Por ejemplo:

$$\text{salario} = \beta_0 + \beta_1 \text{educación} + u$$

- ▶ Noten que si todos los demás factores son constantes ($\Delta u = 0$), entonces:

$$\Delta \text{salario} = \beta_1 \Delta \text{educación}$$

- ▶ β_1 es el parámetro de la pendiente en la relación entre y y x , cuando los factores **no observables** son constantes. **PERO**, en general, ¿son constantes?



Modelo de regresión lineal simple

- ▶ Modelo de regresión lineal simple:

$$y = \beta_0 + \beta_1 x + u \quad (2)$$

- ▶ PERO, en general, ¿son constantes?
- ▶ Difícil decir que u es constante cuando no lo observamos.
- ▶ El supuesto clave para estimar β_1 (cómo x afecta a y) es que:

$$E[u|x] = 0$$

→ el valor promedio de u es igual para cualquier valor de x . Además, es igual a cero, implicando que x no está correlacionada con los factores no observables.

- ▶ Sin esa restricción, no es posible estimar el efecto *ceteris paribus*



Supuestos

1. Linealidad en los parámetros: la función que relaciona y con x es lineal.
2. Media condicional cero:

$$E[u|x] = E[u] = 0$$

→ El valor esperado de los factores inobservables no depende de los valores de x , y dicho promedio es igual a 0, u es media independiente de x .



Ejemplo

$$\textit{Salario} = \beta_0 + \beta_1 \textit{educ} + u$$

¿Qué hay en u ? ¿Como se relaciona con x ?



Regresión Poblacional

- ▶ Si se cumplen los supuestos anteriores (linealidad y $E[u|x] = 0$):
- ▶ Entonces:

$$y = \beta_0 + \beta_1 x + u$$

$$E[y|x] = \beta_0 + \beta_1 E[x|x] + E[u|x]$$

$$E[y|x] = \beta_0 + \beta_1 x$$

- ▶ Por lo tanto, el MRS aproxima la esperanza condicional de y .
- ▶ A la línea $E[y|x]$ se le llama Función de Regresión Poblacional (FRP).



Esperanza condicional

La función de esperanza condicional es la esperanza de una variable Y_i (o su media poblacional) cuando X_i está fijo.

Individuo	Años educ.	Ingreso
María	5	120
Juan	5	100
Pedro	4	80
Catalina	2	50

FEC para cada nivel de educación:

$$E[Y_i | X_i = 5] = 110$$


$$E[Y_i | X_i = 4] = 80$$

$$E[Y_i | X_i = 2] = 50$$

$$E[Y_i] = 87,5$$



Regresión Poblacional: FRP



Interpretación

$$y = \beta_0 + \beta_1 x + u$$

$$E[y|x] = \beta_0 + \beta_1 x$$

Noten que:

$$\beta_1 = \frac{\Delta E[y|x]}{\Delta x}$$

→ es la pendiente de la Función de la FRP, cuando x aumenta en una unidad, el valor esperado de y cambia en β_1 unidades.

$$\beta_0 = E[y|x = 0]$$

→ es el intercepto de la FRP, el valor medio de y cuando x es igual a cero.



Estimación

- ▶ Objetivo: estimar los parámetros poblacionales a partir de una muestra.
- ▶ Sea el modelo poblacional: $y = \beta_0 + \beta_1 x + u$
- ▶ Entonces, para cada $i = 1, \dots, n$ de una muestra podemos escribir:

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

donde u_i es el término de error para la observación i .



Mínimos Cuadrados Ordinarios

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + \hat{u}_i \quad \forall i = 1, \dots, n$$

Definiciones:

- ▶ $\hat{\beta}_0$: estimador de β_0
- ▶ $\hat{\beta}_1$: estimador de β_1
- ▶ $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$: valor predicho/estimado de y_i
- ▶ $\hat{u}_i = y_i - \hat{y}_i$ residuo. El residuo es el análogo muestral del error.
- ▶ Objetivo: encontrar los estimadores $\hat{\beta}$ más parecidos a los parámetros β , los $\hat{y}_i$ más parecidos a y_i , los $\hat{u}_i$ más cercanos a 0.
- ▶ MCO (Mínimos Cuadrados Ordinarios): encuentra los β 's que minimizan la suma de los residuos al cuadrado:

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$



Estimación de β MCO

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Condiciones de primer orden:

$$[\hat{\beta}_0] : \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \Rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$[\hat{\beta}_1] : \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \Rightarrow \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)}$$

Noten que todas estas variables están en la data. Entonces podemos obtener estos estimadores.



Tarea

► Muestre que:

$$\sum_i^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_i^n (x_i - \bar{x})y_i = \sum_i^n (y_i - \bar{y})x_i.$$



Regresión Muestral (FRM)


1. Una vez que estimamos $\hat{\beta}_0$ y $\hat{\beta}_1$, obtenemos la función de regresión muestral (FRM):

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

2. La FRM que se obtiene de una muestra es la versión estimada de la función de regresión poblacional (FRP).
3. En general, la FRP es desconocida y uno se basa en una muestra para estimarla.
4. Valor ajustado o predicho: $\hat{y}$.



Mínimos Cuadrados Ordinarios




Un ejemplo: relación entre educación y sueldos

- Tomamos la relación entre años de educación y sueldos por hora en EE. UU.

$$\text{salario}_i = \beta_0 + \beta_1 \text{educación}_i + \epsilon_i$$

► Colab




Un ejemplo

- ▶ Años de educación y salarios por hora en Estados Unidos.

MCO: $\hat{\text{salario}} = 0,095 + 0,54 \text{educación}$

- ▶ La línea de regresión minimiza los residuos al cuadrado.



Propiedades aritméticas de MCO

1. Los residuales suman cero:

$$\sum_i \hat{u}_i = 0 \quad \Rightarrow \quad \bar{\hat{u}} = 0$$

2. x es ortogonal a los residuos:

$$\sum_i x_i \hat{u}_i = 0$$

3. El promedio muestral de la variable dependiente y_i es igual al promedio muestral de la estimación $\hat{y}_i$: $\bar{y} = \bar{\hat{y}}$
4. La línea de regresión pasa por el promedio de los datos:

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$



Método de momentos

$$y = \beta_0 + \beta_1 x + u \quad (3)$$

$$E(u) = 0 = E(y - \beta_0 - \beta_1 x) \quad (4)$$

$$E(xu) = 0 = E[x(y - \beta_0 - \beta_1 x)] \quad (5)$$

Se eligen estimaciones de los parámetros β_0 y β_1 que resuelvan las contrapartes muestrales.



Método de momentos

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (6)$$

$$\sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (7)$$



Estimación de β MCO

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Condiciones de primer orden:

$$[\hat{\beta}_0] : \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$[\hat{\beta}_1] : \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$



Descomposición de la varianza muestral

- ▶ Sea SST la suma de cuadrados totales (total sum of squares):

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

- ▶ Sea SSE la suma de cuadrados explicados (explained sum of squares):

$$SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- ▶ Sea SSR la suma de cuadrados no explicados (residual sum of squares):

$$SSR = \sum_{i=1}^n \hat{u}_i^2$$

Se puede demostrar que:

$$SST = SSE + SSR$$



Bondad de Ajuste: R^2

- ▶ A partir de esta relación se define:

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

- ▶ Bondad de ajuste: la proporción de la varianza muestral de y que es explicada por x .
- ▶ Como $0 \leq SSE \leq SST$, entonces $0 \leq R^2 \leq 1$.
- ▶ Cuanto más cercano a 1, más de la variabilidad de y es explicada por el modelo.



Cambio de unidades de medición

- ▶ Si la variable independiente se divide o se multiplica por una constante distinta de cero, c , entonces el coeficiente de la pendiente de MCO se multiplica por c o se divide entre c , respectivamente.
- ▶ Cambiar sólo las unidades de medición de la variable independiente no afecta el intercepto.
- ▶ La bondad de ajuste del modelo no depende de las unidades de medición de las variables.



Supuesto 1 RLS

En el modelo poblacional, la variable dependiente, y , está relacionada con la variable independiente, x , y con el error (o perturbación), u , de la manera siguiente:

$$y = \beta_0 + \beta_1 x + u$$

donde β_0 y β_1 representan los parámetros poblacionales, del intercepto y pendiente, respectivamente. u contiene los efectos no observables que afectan a y , u no debe confundirse con los residuales.



Supuesto 2 RLS

Se cuenta con una muestra **aleatoria** de tamaño n ,
 $\{(x_i, y_i) : i = 1, 2, \dots, n\}$.



Supuesto 3 RLS

No todos los valores muestrales de x , a saber $\{x_i, i = 1, \dots, n\}$, son iguales, es decir, no todos tienen el mismo valor.



Supuesto 4 RLS

Para todo valor de la variable explicativa, el valor esperado del error u es cero.

$$E(u|x) = 0.$$



Insesgamiento de los estimadores de MCO

Si se cumplen los supuestos 1-4 RLS, los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ son insesgados:

$$E(\hat{\beta}_0|x) = \beta_0$$

$$E(\hat{\beta}_1|x) = \beta_1$$

El insesgamiento es una propiedad de las distribuciones muestrales de $\hat{\beta}_0$ y $\hat{\beta}_1$. No dice nada acerca de las estimaciones que se obtienen a partir de una determinada muestra. Se espera que, si la muestra es de alguna manera “representativa”, la estimación estará “cerca” del valor poblacional.



Inesgamiento de los estimadores de MCO

- ▶ Si u contiene factores que afectan a y que están correlacionados con x , puede obtenerse una **correlación espuria**.
- ▶ Es decir, se encuentra una relación entre x e y que en realidad se debe a factores no observados que afectan a y que resultan estar correlacionados con x .



Supuesto 5 RLS

El error u tiene la misma varianza para cualquier valor de la variable explicativa.

$$Var(u|x) = \sigma^2$$

La varianza de los factores inobservables, u , condicionales en x , es constante. Esto se conoce como el supuesto de **homocedasticidad** o de **varianza constante**.



Varianza de los estimadores de mínimos cuadrados ordinarios

Considerando el supuesto 5 RLS, tenemos:

$$Var(\hat{\beta}_1|x) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$Var(\hat{\beta}_0|x) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

