

Econometría ICS-294

Clase 5: Estimación del Modelo de Regresión Lineal Múltiple

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Modelo de Regresión Múltiple: Introducción

- En las clases anteriores, vimos el modelo de regresión lineal simple:

$$y = \beta_0 + \beta_1 x + u$$

- Sin embargo, el supuesto de que $E[u|x] = 0$ en dicho modelo es muy fuerte, ya que todas las variables no incluidas van al error.
- Además, si nos interesa la predicción, es muy difícil predecir la variable y en base a una sola variable.
- El modelo de regresión lineal múltiple (RLM) permite esto.



Modelo de Regresión Lineal Múltiple

- A nivel poblacional, el modelo RLM se define como:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

- Asumamos que $E[u|x_1, x_2, \dots, x_k] = 0$.
- Interpretación de los parámetros β :
- Por ejemplo, si todas las variables excepto x_1 permanecen constantes:

$$\Delta E[y|x_1, x_2, \dots, x_k] = \beta_1 \Delta x_1$$

$$\Rightarrow \beta_1 = \frac{\Delta E[y|x_1, x_2, \dots, x_k]}{\Delta x_1}$$

- Interpretación: Cuando x_1 cambia en una unidad, el valor esperado de y cambia en β_1 unidades, **manteniendo todas las demás variables incluidas constantes**.

Es como una derivada parcial!



Modelo de Regresión Múltiple: Estimación MCO

- Al agregar más variables al modelo para poder estudiar el efecto de x , ceteris paribus estas otras variables.
- Por ejemplo, al estudiar el efecto de educación en salario, queremos dejar la inteligencia constante (IQ).
- Al incluir esta variable en la regresión, podemos ver cuánto afecta un año más de educación en salario, dejando constante IQ.
- De hecho, si agregamos la variable IQ, el coeficiente de educación que obtenemos se hace más pequeño.

$$MCO \text{ Simple: } \hat{\text{salario}} = 0,09 + 0,54 \cdot \text{educacion}$$

$$MCO \text{ Múltiple: } \hat{\text{salario}} = 0,065 + 0,37 \cdot \text{educacion} + 0,20 \cdot IQ$$

- Ahora vamos a ver cómo estimar los $\hat{\beta}$ del modelo de regresión múltiple.



Modelo de Regresión Lineal Múltiple: Estimación

Dada una muestra de n individuos, tenemos la siguiente ecuación:

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik} + \hat{u}_i, \quad \forall i = 1, \dots, n$$

Igual que en el modelo RLS, los **residuos** vienen dados por:

$$\hat{u}_i = y_i - \hat{y}_i$$

$$\hat{u}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik})$$



MCO para el Modelo Lineal Múltiple

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} \sum_i \hat{u}_i^2$$

Es decir,

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} \sum_i \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right)^2$$

CPO:

$$\hat{\beta}_0 : \sum_i \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right) = 0$$

$$\hat{\beta}_1 : \sum_i x_{i1} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right) = 0$$

...

$$\hat{\beta}_k : \sum_i x_{ik} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_k x_{ik} \right) = 0$$

Existen $k + 1$ condiciones de primer orden para $k + 1$ incógnitas.



Notación matricial modelo poblacional

- El modelo de regresión lineal múltiple cada individuo i es:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + u_i \quad \forall i = 1, \dots, n$$

- Matricialmente, lo podemos expresar:

$$y_i = \mathbf{x}_i^\top \beta + u_i \quad \forall i = 1, \dots, n$$

con

$$\mathbf{x}_i = \begin{pmatrix} 1 \\ x_{i1} \\ \vdots \\ x_{ik} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

- Noten que son n ecuaciones (una para cada individuo).



Notación

■

$$y = X\beta + u$$

con

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix}, \quad u = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}$$

donde u y y son vectores de $n \times 1$ y X es una matriz de $n \times (k + 1)$.



Ejemplo: $n = 5$, dos variables: x_1, x_2

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_5 \end{bmatrix} = \beta_0 \begin{bmatrix} 1 \\ 1 \\ \dots \\ 1 \end{bmatrix} + \beta_1 \begin{bmatrix} x_{11} \\ x_{12} \\ \dots \\ x_{15} \end{bmatrix} + \beta_2 \begin{bmatrix} x_{21} \\ x_{22} \\ \dots \\ x_{25} \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \dots \\ u_5 \end{bmatrix}$$

Re-escribiendo:

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_5 \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{12} & x_{22} \\ \dots & \dots & \dots \\ 1 & x_{15} & x_{25} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \dots \\ u_5 \end{bmatrix}$$

$$y = X\beta + u$$



Mínimos Cuadrados Ordinarios (MRL Múltiple)

- Como antes, podemos definir:
 - $\hat{\beta}$: estimadores de los β dimensión, $(k + 1) \times 1$
 - $\hat{y} = X\hat{\beta}$: Valores predichos de y , dimensión $n \times 1$
 - Por lo tanto, los residuos en forma matricial:

$$\hat{u} = y - \hat{y} = y - X\hat{\beta}$$



Recordar

- **Derivadas**

Si a y β son vectores y A una matriz simétrica, entonces:

1. $\frac{da^\top \beta}{d\beta} = a$

2. $\frac{d\beta^\top A \beta}{d\beta} = 2A\beta$

- **Propiedades de la traspuesta**

Sean D y E matrices: $(DE)^\top = E^\top D^\top$

- **Potencias**

$$\sum_i (s_i)^2 = s^\top s$$



Mínimos Cuadrados Ordinarios (MRL Múltiple)

$$\min \sum_{i=1}^n \hat{u}_i^2 \Rightarrow \min_{\hat{\beta}} \hat{u}^\top \hat{u}$$

- La suma de los residuos al cuadrado es:

$$\begin{aligned}\hat{u}^\top \hat{u} &= (y - X\hat{\beta})^\top (y - X\hat{\beta}) \\ &= y^\top y - \hat{\beta}^\top X^\top y - y^\top X\hat{\beta} + \hat{\beta}^\top X^\top X\hat{\beta} \\ &= y^\top y - 2y^\top X\hat{\beta} + \hat{\beta}^\top X^\top X\hat{\beta}\end{aligned}$$

- Entonces, condiciones de primer orden:

$$\frac{\partial \hat{u}^\top \hat{u}}{\partial \hat{\beta}} = 0 \Rightarrow -2X^\top y + 2X^\top X\hat{\beta} = 0 \Rightarrow \hat{\beta} = (X^\top X)^{-1} X^\top y$$

- Note que precisamos suponer que X tiene rango $(k+1)$ completo $\Rightarrow X^\top X$ es invertible.
- Las $k+1$ ecuaciones $X^\top y = X^\top X\hat{\beta}$ son llamadas ecuaciones normales para MCO.
- Condición de segundo grado: $\frac{d^2 \hat{u}^\top \hat{u}}{d\hat{\beta} d\hat{\beta}} = 2X^\top X$ positiva definida.



Propiedades algebraicas

- Al igual que el caso de regresión simple, las propiedades algebraicas se derivan de las CPO.
- Propiedades 1 y 2: $X^\top \hat{u} = 0$:

$$\sum_i \hat{u}_i = 0 \quad (\text{propiedad 1})$$

$$\sum_i x_{i1} \hat{u}_i = 0 \quad (\text{propiedad 2})$$

$$\sum_i x_{i2} \hat{u}_i = 0 \quad (\text{propiedad 2})$$

...

$$\sum_i x_{ik} \hat{u}_i = 0 \quad (\text{propiedad 2})$$

- Propiedad 3: La media de la variable observada y es igual a la media de la variable predicha $\hat{y}$:

$$\bar{y} = \bar{\hat{y}}$$

- Propiedad 4: El punto $(\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k, \bar{y})$ pasa por la curva de regresión.



Bondad de Ajuste: R^2

El R^2 nos dice que la proporción de la varianza muestral de y es explicada por nuestra regresión MCO. Recordando las definiciones:

- Suma de cuadrados explicada: $SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- Suma de cuadrados residual: $SSR = \sum_{i=1}^n \hat{u}_i^2$
- Suma de cuadrados total: $SST = \sum_{i=1}^n (y_i - \bar{y})^2$

La fórmula para el R^2 es igual que en el caso de la regresión simple:

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$



Bondad de Ajuste: R^2 ajustado

- R^2 crece (o queda igual) a medida que se agregan más variables al modelo. Esto ocurre incluso si la variable agregada no es relevante en el modelo poblacional.
- Necesitamos una medida que penalice agregar variables irrelevantes.
- Se define el R^2 ajustado como:

$$\overline{R^2} = 1 - \frac{n-1}{n-k-1} \frac{SSR}{SST}$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Modelo: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$, $n = 5$.

Base de datos:

Individuos	unos	x_1 (experiencia)	x_2 (educación)	y (salario)
Juan	1	12	93	769
Pedro	1	18	119	808
Sofia	1	14	108	825
Caro	1	12	96	650
Alex	1	11	74	562



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Modelo: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$, $n = 5$.

Base de datos:

Individuos	unos	x_1 (experiencia)	x_2 (educación)	y (salario)
Juan	1	12	93	769
Pedro	1	18	119	808
Sofia	1	14	108	825
Caro	1	12	96	650
Alex	1	11	74	562

$$X = \begin{bmatrix} 1 & 12 & 93 \\ 1 & 18 & 119 \\ 1 & 14 & 108 \\ 1 & 12 & 96 \\ 1 & 11 & 74 \end{bmatrix} \quad X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix}$$

$$X^T X = \begin{bmatrix} 5 & 67 & 490 \\ 67 & 929 & 6736 \\ 490 & 6736 & 49166 \end{bmatrix}$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Modelo: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$, $n = 5$.

Base de datos:

Individuos	unos	x_1 (experiencia)	x_2 (educación)	y (salario)
Juan	1	12	93	769
Pedro	1	18	119	808
Sofia	1	14	108	825
Caro	1	12	96	650
Alex	1	11	74	562

$$X = \begin{bmatrix} 1 & 12 & 93 \\ 1 & 18 & 119 \\ 1 & 14 & 108 \\ 1 & 12 & 96 \\ 1 & 11 & 74 \end{bmatrix} \quad X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix}$$

$$X^T X = \begin{bmatrix} 5 & 67 & 490 \\ 67 & 929 & 6736 \\ 490 & 6736 & 49166 \end{bmatrix} \quad (X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

$$X^T y = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix} \times \begin{bmatrix} 769 \\ 808 \\ 825 \\ 650 \\ 562 \end{bmatrix} = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

$$X^T y = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 12 & 18 & 14 & 12 & 11 \\ 93 & 119 & 108 & 96 & 74 \end{bmatrix} \times \begin{bmatrix} 769 \\ 808 \\ 825 \\ 650 \\ 562 \end{bmatrix} = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix} =$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Entonces tenemos: $(X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$

$$X^T y = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Entonces tenemos: $(X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$

$$X^T y = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$

Multiplicando obtenemos los estimadores:

$$\hat{\beta} = (X^T X)^{-1} X^T y = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 140,59 \\ -16,79 \\ 8,24 \end{bmatrix}$$



Ejemplo: obtener $\hat{\beta} = (X^T X)^{-1} X^T y$

Entonces tenemos: $(X^T X)^{-1} = \begin{bmatrix} 8,80 & 0,19 & -0,11 \\ 0,19 & 0,17 & -0,02 \\ -0,11 & -0,02 & 0,00 \end{bmatrix}$

$$X^T y = \begin{bmatrix} 3614 \\ 49304 \\ 360757 \end{bmatrix}$$

Multiplicando obtenemos los estimadores:

$$\hat{\beta} = (X^T X)^{-1} X^T y = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 140,59 \\ -16,79 \\ 8,24 \end{bmatrix}$$

Si quisieramos la matrix de prediccion de y, simplemente calculamos:

$$\hat{y} = X \hat{\beta}$$



En general

$$X^T X = \begin{pmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} & \cdots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1}x_{i2} & \cdots & \sum_{i=1}^n x_{i1}x_{ik} \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i1}x_{i2} & \sum_{i=1}^n x_{i2}^2 & \cdots & \sum_{i=1}^n x_{i2}x_{ik} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{i1}x_{ik} & \sum_{i=1}^n x_{i2}x_{ik} & \cdots & \sum_{i=1}^n x_{ik}^2 \end{pmatrix}$$

$$X^T y = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1}y_i \\ \vdots \\ \sum_{i=1}^n x_{ik}y_i \end{pmatrix}$$



En R

```
experiencia <- c(12,18,14,12,11)
educacion<- c(93,119,108,96,74)
y_sal<-c(769,808,825,650,562)
unos<- c(1,1,1,1,1)
X <- cbind(unos,experiencia, educacion)
X_T<- t(X)

X_TX<- X_T%*%X
X_TX_inv<- solve(X_TX)
X_TY_sal<- X_T%*%y_sal
beta_hat<- X_TX_inv%*%X_TY_sal
Y_hat<- X%*%beta_hat
u_hat <- y_sal-Y_hat
```



Regresión

```
lm(formula = y_sal ~ experiencia + educacion)
```

Residuals:

1	2	3	4	5
63.878	-10.538	29.907	-79.832	-3.415

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	140.586	224.616	0.626	0.595
experiencia	-16.790	30.964	-0.542	0.642
educacion	8.237	5.109	1.612	0.248

Residual standard error: 75.73 on 2 degrees of freedom

Multiple R-squared: 0.7751, Adjusted R-squared: 0.5501

F-statistic: 3.446 on 2 and 2 DF, p-value: 0.2249

