

Econometría ICS-294

Clase 6: Propiedades estadísticas del estimador MCO

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Resumen clase anterior

- Vimos la forma matricial del modelo de regresión lineal múltiple: $y = X\beta + u$

- Demostramos que por MCO se puede obtener: $\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = (X^\top X)^{-1} X^\top y$

Interpretación $\hat{\beta}_i$: Cuando cambia x_i en una unidad, en promedio y cambia $\hat{\beta}_i$ unidades, manteniendo todas las demás variables explicativas (x_{-i}) constantes.



Supuestos Clásicos

¿ $\hat{\beta}$ es un buen estimador para β ? ¿Qué significa que sea bueno?

Supuestos clásicos:

1. Linealidad en parámetros
2. Muestra aleatoria
3. Condición de identificación
4. Ortogonalidad
5. Homocedasticidad



Supuesto 1: Linealidad en Parámetros

- ▶ La relación poblacional entre las variables sigue un modelo lineal:

$$y = X\beta + u \quad (1)$$

$$= \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u \quad (2)$$

donde $\beta_0, \beta_1, \dots, \beta_k$ son parámetros desconocidos y u es una variable no observable llamada término de error o perturbación.

- ▶ Si el modelo analítico no es lineal en los parámetros, hay que linealizarlo, en la medida de lo posible.
- ▶ Por ejemplo:

$$Y = AK^{\alpha_1} Q^{\alpha_2} L^{\alpha_3}$$

se lineariza como

$$\log Y = \log A + \alpha_1 \log K + \alpha_2 \log Q + \alpha_3 \log L$$



Supuesto 2: Muestra Aleatoria

- ▶ Las n observaciones provienen de una muestra aleatoria de la población,

$$\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i) : i = 1, 2, \dots, n\}$$

- ▶ Esto significa que las observaciones son independientes unas de otras, lo que implica que

$$\text{cov}(u_i, u_j | X) = 0 \quad \forall i \neq j$$

- ▶ En series de tiempo lo anterior implica que los errores no tienen autocorrelación.



Supuesto 3: Condición de Identificación (No multicolinealidad perfecta)

- ▶ X tiene rango columna completo $k + 1$.
- ▶ No hay relaciones lineales exactas entre las variables independientes.
- ▶ Esto implica:
 - ▶ Las columnas de X son linealmente independientes.
 - ▶ Existe la inversa de $X^T X$.
 - ▶ $n \geq k + 1$.

Ejemplo de violación a este supuesto: $x_2 = 2x_1$. La fila 2 es linealmente dependiente de la 1.



Supuesto 4: Ortogonalidad (Exogeneidad)

- ▶ $E[u|X] = E(u|x_1, x_2, \dots, x_k) = 0$.
- ▶ Esto implica que:
 - ▶ $E[X^\top u] = 0$: la covarianza entre las x y el error es cero.
 - ▶ $E(y|X) = E(X\beta + u|X) = X\beta$.

Vamos a ver que este supuesto va a ser el supuesto clave para interpretar causalmente los coeficientes.



Supuesto 4: Ortogonalidad (Exogeneidad)

- ▶ $E[u|X] = E(u|x_1, x_2, \dots, x_k) = 0$.
- ▶ Esto implica que:
 - ▶ $E[X^\top u] = 0$: la covarianza entre las x y el error es cero.
 - ▶ $E(y|X) = E(X\beta + u|X) = X\beta$.
- ▶ Vamos a ver que este supuesto va a ser el supuesto clave para interpretar causalmente los coeficientes.
- ▶ Este supuesto puede no cumplirse por varias razones:
 - ▶ Omisión de una variable que está correlacionada con alguna x .
 - ▶ Errores de medición en los regresores.
- ▶ Por desgracia, muy pocas veces se sabe con seguridad si el valor promedio de los factores no observables de hecho no está relacionado con las variables explicativas. **Pero este es el supuesto crítico.**



Supuesto 5: Homocedasticidad y no autocorrelación

- ▶ La varianza del error no depende de X :

$$\text{Var}(u_i|x_1, \dots, x_k) = E[u_i^2|x] = \sigma^2$$


- ▶ En caso de que el supuesto no se cumpla, se dice que el modelo presenta heterocedasticidad.
- ▶ Ejemplo donde no se cumpliría esta condición: si tenemos salario en función de años de escolaridad, la varianza de u es probablemente menor para escolaridades pequeñas.
- ▶ Con esto, la varianza condicional del vector u queda: $\text{Var}(u|X) = \sigma^2 I$.
- ▶ La covarianza de los errores es cero:

$$\text{Covar}(u_i, u_j|x_1, \dots, x_k) = 0$$




Supuesto 5: Homocedasticidad

- Homocedasticidad en un modelo simple (mismo σ).



- Heterocedasticidad en un modelo simple.



Resumen Supuestos

1. Linealidad en parámetros ($y = X\beta + u$).
2. Muestra aleatoria.
3. X tiene rango completo ($k + 1$), es decir, todas las variables son linealmente independientes.
4. Ortogonalidad: $E[u|X] = 0$.
5. Homocedasticidad y no-autocorrelación: $V(u|X) = \sigma^2 I$



Propiedades Estadísticas de los Estimadores $\hat{\beta}$

Bajo los supuestos clásicos, los estimadores MCO cumplen lo siguiente:

1. $\hat{\beta}$ es insesgado: $E(\hat{\beta}) = \beta$.
2. $V(\hat{\beta}|X) = (X^\top X)^{-1}\sigma^2$.
3. Teorema de Gauss-Markov: $\hat{\beta}$ es el estimador lineal insesgado de menor varianza (MELI-BLUE).



El Estimador MCO es Insesgado

- ▶ Teorema: Bajo los supuestos 1 a 4, el estimador MCO de β es insesgado.
- ▶ Demostración:

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (3)$$

$$= (X^T X)^{-1} X^T (X\beta + u) \quad (4)$$

$$= \beta + (X^T X)^{-1} X^T u \quad (5)$$

$$E(\hat{\beta}|X) = \beta + (X^T X)^{-1} X^T E(u|X) \quad (6)$$

$$= \beta \quad (7)$$

- ▶ Esto implica que el promedio de los estimadores $\hat{\beta}$ obtenidos con todas las muestras aleatorias posibles es igual a β .



Varianza del Estimador MCO

- Teorema: Bajo los supuestos 1 a 5, la varianza del estimador MCO de β es $\text{Var}(\hat{\beta}|X) = \sigma^2(X^\top X)^{-1}$.
- Demostración:

$$\text{Var}(\hat{\beta}|X) = E[(\hat{\beta} - E(\hat{\beta}))(\hat{\beta} - E(\hat{\beta}))^\top | X] \quad (8)$$

$$= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^\top | X] \quad (9)$$

$$= E[(X^\top X)^{-1} X^\top u u^\top X (X^\top X)^{-1} | X] \quad (10)$$

$$= (X^\top X)^{-1} X^\top E[u u^\top | X] X (X^\top X)^{-1} \quad (11)$$

$$= (X^\top X)^{-1} X^\top \sigma^2 I X (X^\top X)^{-1} \quad (12)$$

$$= \sigma^2 (X^\top X)^{-1} (X^\top X) (X^\top X)^{-1} \quad (13)$$

$$= \sigma^2 (X^\top X)^{-1} \quad (14)$$

- nota: $\hat{\beta} = \beta + (X^\top X)^{-1} X^\top u$

