

Econometría ICS-294

Clase 7: Propiedades estadísticas del estimador MCO

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Estimador MCO de σ^2

La matriz de varianzas-covarianzas viene dada por:

$$\text{Var}(\hat{\beta}|X) = \sigma^2(X^\top X)^{-1}$$

Notar que $(X^\top X)^{-1}$ es una matriz que se observa en los datos.
Pero, σ^2 es la varianza del error poblacional. NO es observable.



Estimador MCO de σ^2

El estimador $\hat{\sigma}^2$ de σ^2 :

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k - 1} = \frac{SSR}{n - k - 1}$$

- El término $n - k - 1$ son los grados de libertad (gl) para el problema general de MCO con n observaciones y k variables independientes.
- Como en un modelo de regresión con k variables independientes y un intercepto hay $k + 1$ parámetros.
- $gl = (\text{observaciones}) - (\text{cantidad de parámetros estimados})$.
- Bajo los supuestos del teorema de Gauss-Markov se cumple que $E[\hat{\sigma}^2|X] = \sigma^2$.



Varianza Estimada de Cada Estimador $\hat{\beta}_j$

$$\hat{\text{Var}}(\hat{\beta}|X) = \hat{\sigma}^2(X^\top X)^{-1}$$

Matriz de $(k+1) \times (k+1)$ de varianzas-covarianzas, tal que:

- El elemento de la diagonal $a_{1,1}$ es $\hat{\text{Var}}(\hat{\beta}_0)$.
- El elemento de la diagonal $a_{2,2}$ es $\hat{\text{Var}}(\hat{\beta}_1)$.
- Generalizando: el elemento de la diagonal $a_{j+1,j+1}$ es $\hat{\text{Var}}(\hat{\beta}_j)$.



Varianza del Estimador MCO: Ejemplo

- Supuestos clásicos $\Rightarrow \hat{V}(\hat{\beta}) = \hat{\sigma}^2(X^\top X)^{-1}$.
- De los datos obtenemos:

$$(X^\top X)^{-1} = \begin{bmatrix} 0,05987 & -0,00177 & -0,00035 \\ -0,00177 & 0,00030 & -0,00002 \\ -0,00035 & -0,00002 & 0,00001 \end{bmatrix};$$

$$\hat{\sigma}^2 = \frac{SSR}{n - k - 1} = 141925$$



Varianza del Estimador MCO: Ejemplo

- Supuestos clásicos $\Rightarrow \hat{V}(\hat{\beta}) = \hat{\sigma}^2(X^\top X)^{-1}$.
- De los datos obtenemos:

$$(X^\top X)^{-1} = \begin{bmatrix} 0,05987 & -0,00177 & -0,00035 \\ -0,00177 & 0,00030 & -0,00002 \\ -0,00035 & -0,00002 & 0,00001 \end{bmatrix}; \quad \hat{\sigma}^2 = 141925$$

- Entonces, podemos calcular:

$$\hat{V}(\hat{\beta}) = \hat{\sigma}^2(X^\top X)^{-1} = \begin{bmatrix} 8497,57 & -250,80 & -49,04 \\ -250,80 & 42,90 & -3,22 \\ -49,04 & -3,22 & 0,91 \end{bmatrix}$$

- En la diagonal principal, tienen la varianza de cada uno de los estimadores.
- Ejemplo: $\hat{V}(\hat{\beta}_1) = 42,6$. Es decir, los $\hat{se}(\hat{\beta}_1) = \sqrt{\hat{V}(\hat{\beta}_1)} = 6,53$



El Caso Particular de Regresión con una Sola Variable Independiente

En el modelo de regresión simple $y = \beta_0 + \beta_1 x + u$, sigue cumpliéndose lo anterior.

$$\hat{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- Si x tiene más variabilidad, hace que $\hat{\beta}$ sea más preciso (tengo más información).
- Si la varianza del residuo es más grande, mi estimador es menos preciso. Mi modelo no explica mucho de y .

