

Econometría ICS-294

Clase 11: Inferencia sobre un conjunto de parámetros

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Test de hipótesis sobre un conjunto de parámetros

- A menudo estamos interesados en testear hipótesis para varios parámetros a la vez.
- Por ejemplo si dos coeficientes son 0 al mismo tiempo.
- En ese caso, las hipótesis se verían de la siguiente forma:

$$H_0 : \beta_1 = \beta_2 = 0$$

$$H_1 : \text{Al menos uno} \neq 0$$

- Cuando se rechaza la hipótesis nula se dice que x_1 y x_2 son conjuntamente significativas al correspondiente nivel de significancia.
- Noten que en este caso, el test NO dice cuál de las variables tiene un efecto en y . Puede ser una sola, varias o todas.
- Para esto vamos a usar un estadístico F.



Repaso relevante para esta clase

Partiendo de $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$, calculo por MCO y obtengo la predicción: $\hat{y}$. Definiciones:

$SST : \sum_i (y_i - \bar{y})^2 \rightarrow$ variabilidad de y

$SSE : \sum_i (\hat{y}_i - \bar{y})^2 \rightarrow$ lo explicado por mi modelo

$SSR : \sum_i \hat{u}_i^2 \rightarrow$ lo que mi modelo no explica/se equivoca

$SST : SSE + SSR \rightarrow$ lo que explico + lo que no explico con mi modelo

$R^2 : 1 - \frac{SSR}{SST} \rightarrow$ fracción de la variabilidad de y que es explicada por mi modelo



Repaso: Si agrego variables relevantes, cae mi SSR

Supongan que parto estimando $y = \beta_0 + \beta_1 x_1 + u$.

- $SST = SSE + SSR$
- $SST = \text{lo que explico} + \text{lo que no explico con el modelo}$
- $R^2 = 1 - \frac{SSR}{SST}$
el % de la variabilidad de y que es explicada por mi modelo

¿Qué pasa si agrego a mi modelo una variable x_2 relevante para explicar y ?



Repaso: Si agrego variables relevantes, cae mi SSR

Supongan que parto estimando $y = \beta_0 + \beta_1 x_1 + u$.

- $SST = SSE + SSR$
- $SST = \text{lo que explico} + \text{lo que no explico con el modelo}$
- $R^2 = 1 - \frac{SSR}{SST}$
el % de la variabilidad de y que es explicada por mi modelo

¿Qué pasa si agrego a mi modelo una variable x_2 relevante para explicar y ? Cae mi SSR y aumenta mi R^2 .

$$SST = \uparrow SSE + \downarrow SSR$$

$$\uparrow R^2 = 1 - \frac{\downarrow SSR}{SST}$$



Test de hipótesis y modelo restringido

- Entonces, una buena forma de testear si variables son irrelevantes para explicar la variable y (tienen $\beta's = 0$) es:
- Mirar las diferencias entre el SSR de un modelo que las incluye (modelo unrestricted: SSR_{ur}) y el SSR de un modelo que no las incluye (modelo restricted: SSR_r).
- Cuanto más grande sea la diferencia $SSR_r - SSR_{ur}$ más seguros estaremos de que las variables en cuestión son relevantes para explicar y .
- ¿Cuál es el signo de esta diferencia $SSR_r - SSR_{ur}$?



Test de hipótesis y modelo restringido

- Entonces, una buena forma de testear si variables son irrelevantes para explicar la variable y (tienen $\beta's = 0$) es:
- Mirar las diferencias entre el SSR de un modelo que las incluye (modelo unrestricted: SSR_{ur}) y el SSR de un modelo que no las incluye (modelo restricted: SSR_r).
- Cuanto más grande sea la diferencia $SSR_r - SSR_{ur}$ más seguros estaremos de que las variables en cuestión son relevantes para explicar y .
- ¿Cuál es el signo de esta diferencia $SSR_r - SSR_{ur}$?
- $SSR_r - SSR_{ur} \geq 0$



Test: Definiciones

- Sea el modelo: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$
- Nos interesa testear si x_2 o x_3 o ambas son relevantes para el modelo.
Es decir: $H_0 : \beta_2 = \beta_3 = 0$, $H_1 : \text{Al menos uno} \neq 0$



Test: Definiciones

- Sea el modelo: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$
- Nos interesa testear si x_2 o x_3 o ambas son relevantes para el modelo. Es decir: $H_0 : \beta_2 = \beta_3 = 0$, $H_1 : \beta_2 \neq 0$ o $\beta_3 \neq 0$.

Modelo no restringido (UR): se incluyen todas las variables.

- Estimando el modelo no restringido por MCO,

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u \rightarrow \text{obtenemos } SSR_{ur}$$

Modelo Restringido (R): se asume H_0 verdadera y se estima el modelo:

- $y = \beta_0 + \beta_1 x_1 + u \rightarrow \text{obtenemos } SSR_r$
- Rechazamos H_0 a medida que $SSR_r - SSR_{ur}$ sea mayor. Si se cumpliera H_0 , es decir las variables x_2 y x_3 fueran totalmente irrelevantes, esa diferencia sería cercana a 0.



Test de hipótesis y modelo restringido

- Podemos pensar el test de hipótesis como la comparación entre el modelo original y el modelo restringido (cuando se cumple la H_0).
- Entonces, se puede demostrar que:

$$F = \frac{SSR_r - SSR_{ur}}{SSR_{ur}} \cdot \frac{n - k - 1}{j} \sim F(j, n - k - 1)$$
$$\frac{\frac{SSR_r - SSR_{ur}}{j}}{\frac{SSR_{ur}}{n - k - 1}}$$



Test de hipótesis y modelo restringido

- Podemos pensar el test de hipótesis como la comparación entre el modelo original y el modelo restringido (cuando se cumple la H_0).
- Entonces, se puede demostrar que:

$$F = \frac{SSR_r - SSR_{ur}}{SSR_{ur}} \cdot \frac{n - k - 1}{j} \sim F(j, n - k - 1)$$

- Donde j son las restricciones de exclusión.



Test de hipótesis y modelo restringido

- Podemos pensar el test de hipótesis como la comparación entre el modelo original y el modelo restringido (cuando se cumple la H_0).
- Entonces, se puede demostrar que:

$$F = \frac{SSR_r - SSR_{ur}}{SSR_{ur}} \cdot \frac{n - k - 1}{j} \sim F(j, n - k - 1)$$

- Donde j son las restricciones de exclusión.
- Note que $SSR_r \geq SSR_{ur}$.
- Note que $SSR_r - SSR_{ur}$ va a ser más grande cuanto más importantes son las variables testeadas.



Test de hipótesis y modelo restringido

- Podemos pensar el test de hipótesis como la comparación entre el modelo original y el modelo restringido (cuando se cumple la H_0).
- Entonces, se puede demostrar que:

$$F = \frac{SSR_r - SSR_{ur}}{SSR_{ur}} \cdot \frac{n - k - 1}{j} \sim F(j, n - k - 1)$$

- Donde j son las restricciones de exclusión.
- Note que $SSR_r \geq SSR_{ur}$.
- Note que $SSR_r - SSR_{ur}$ va a ser más grande cuanto más importantes son las variables testeadas.
- El test sobre un conjunto de parámetros se reduce a responder si la disminución relativa en SSR de pasar del modelo restringido al no-restringido es suficientemente grande.



Otra forma de escribirlo

Note que usando $R^2 = 1 - \frac{SSR}{SST}$, el estadístico F también se puede escribir como (demostrar de tarea):


$$F = \frac{(R_{ur}^2 - R_r^2)}{(1 - R_{ur}^2)} \cdot \frac{n - k - 1}{j} \sim F(j, n - k - 1)$$

- ¿Cómo lo interpretan?
- Cuanto más relevantes las variables que estoy testeando, más diferencia va a haber entre el porcentaje explicado por el UR y el explicado por el R.



Zona de rechazo

- Sea α el nivel de significancia, si $F_{\text{estadístico}} > F_{\alpha;j;n-k-1}$ se rechaza H_0 .




Cuanto más grande sea la diferencia entre los modelos, más extremo será el $F_{\text{empírico}}$ y más probable que rechacemos la H_0 .



Distribución F

Distribuciones F y puntos críticos (5% de significancia)



Ejemplo: rendimiento y salario en el baseball

- Se tiene el siguiente modelo para los salarios de los jugadores de baseball:

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{years} + \beta_2 \text{gamesyr} + \beta_3 \text{hrunsyr} + \beta_4 \text{rbisyr} + u$$

donde years es el número de años en la liga, gamesyr el promedio de juegos anuales, hrunsyr el número de home runs y rbisyr el número de corridas gracias a su bateo.

- Se quiere testear que el rendimiento de los jugadores no influye en sus salarios, es decir,

$$H_0 : \beta_3 = \beta_4 = 0$$

$$H_1 : \text{Al menos uno es } \neq 0$$



Ejemplo: rendimiento y salario en el baseball (n=353)

■ **Step 1:** $H_0 : \beta_3 = \beta_4 = 0$, $H_1 : \beta_3 \neq 0$ o $\beta_4 \neq 0$

■ **Step 2:**

1. **Modelo no restringido:**

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{years} + \beta_2 \text{gamesyr} + \beta_3 \text{hrunsyr} + \beta_4 \text{rbisyr} + u$$

obtenemos SSR_{ur} .

2. **Modelo restringido:**

$$\log(\text{salary}) = \gamma_0 + \gamma_1 \text{years} + \gamma_2 \text{gamesyr} + e$$

obtenemos SSR_r .

■ **Step 3:** Calcular $F_{\text{estadístico}} = \frac{(SSR_r - SSR_{ur})}{SSR_{ur}} \cdot \frac{353-5}{2}$

■ **Step 4:** Comparar con el F de la distribución $F(2, 348)$ para 5 % de significatividad.



Ejemplo: rendimiento y salario en el baseball

■ Resultados modelo no restringido:

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{years} + \beta_2 \text{gamesyr} + \beta_3 \text{hrunsyr} + \beta_4 \text{rbisyr} + u$$

Mean dependent var	13.49218	S.D. dependent var	1.182466
Sum squared resid	183.6015	S.E. of regression	0.726354
R-squared	0.626959	Adjusted R-squared	0.622672
F(4, 348)	146.2185	P-value(F)	3.37e-73
Log-likelihood	-385.5072	Akaike criterion	781.0144
Schwarz criterion	800.3467	Hannan-Quinn	788.7069

■ Resultados modelo restringido:

$$\log(\text{salary}) = \gamma_0 + \gamma_1 \text{years} + \gamma_2 \text{gamesyr} + u$$

Mean dependent var	13.49218	S.D. dependent var	1.182466
Sum squared resid	198.3115	S.E. of regression	0.752731
R-squared	0.597072	Adjusted R-squared	0.594769
F(2, 350)	259.3203	P-value(F)	8.22e-70
Log-likelihood	-399.1103	Akaike criterion	804.2206
Schwarz criterion	815.8200	Hannan-Quinn	808.8361



Ejemplo: rendimiento y salario en el baseball

- Resultados modelo no restringido:

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{years} + \beta_2 \text{gamesyr} + \beta_3 \text{hrunsyr} + \beta_4 \text{rbisyr} + u$$

Mean dependent var	13.49218	S.D. dependent var	1.182466
Sum squared resid	183.6015	S.E. of regression	0.726354
R-squared	0.626959	Adjusted R-squared	0.622672
F(4, 348)	146.2185	P-value(F)	3.37e-73
Log-likelihood	-385.5072	Akaike criterion	781.0144
Schwarz criterion	800.3467	Hannan-Quinn	788.7069

- Resultados modelo restringido: $\log(\text{salary}) = \gamma_0 + \gamma_1 \text{years} + \gamma_2 \text{gamesyr} + u$

Mean dependent var	13.49218	S.D. dependent var	1.182466
Sum squared resid	198.3115	S.E. of regression	0.752731
R-squared	0.597072	Adjusted R-squared	0.594769
F(2, 350)	259.3203	P-value(F)	8.22e-70
Log-likelihood	-399.1103	Akaike criterion	804.2206
Schwarz criterion	815.8200	Hannan-Quinn	808.8361

- Test de hipótesis conjunto para $H_0 : \beta_3 = \beta_4 = 0$

$$F = \frac{(198,31 - 183,60)}{183,60} \cdot \frac{353 - 4 - 1}{2} = 13,94$$

- Comparamos con el punto crítico de $F(2, 348)$ con 5 % de significancia que es 3.02, por lo que rechazamos la hipótesis nula. Es decir, los home runs o las corridas son importantes para explicar el salario.



Ejercicio

Use los datos de las tablas anteriores para comprobar que uno también puede calcular el F -estadístico usando la fórmula con los R^2 de los modelos restringidos y no restringidos:

$$F = \frac{(0,6270 - 0,5971)}{(1 - 0,6270)} \cdot \frac{353 - 4 - 1}{2} = 13,94$$



Ejemplo: rendimiento y salario en el baseball

Model 1: OLS, using observations 1–353
Dependent variable: lsalary

	coefficient	std. error	t-ratio	p-value	
const	11.4267	0.116641	97.96	1.95e-255	***
years	0.0692793	0.0121017	5.725	2.24e-08	***
gamesyr	0.0123486	0.00263599	4.685	4.03e-06	***
hrunsyr	0.0109999	0.0155795	0.7060	0.4806	
rbisyr	0.0124562	0.00691497	1.801	0.0725	*
Mean dependent var	13.49218	S.D. dependent var	1.182466		
Sum squared resid	183.6015	S.E. of regression	0.726354		
R-squared	0.626959	Adjusted R-squared	0.622672		
F(4, 348)	146.2185	P-value(F)	3.37e-73		
Log-likelihood	-385.5072	Akaike criterion	781.0144		
Schwarz criterion	800.3467	Hannan-Quinn	788.7069		

- Noten que si bien encontramos que los coeficientes conjuntamente son diferentes a 0, los coeficientes para hrunsyr y rbisyr son positivos, sin embargo, no es posible rechazar la insignificancia individual de cada uno de ellos (con $\alpha = 5\%$).



F-test y el problema de multi-colinealidad

- Noten que en el ejemplo anterior, no podíamos rechazar que cada coeficiente era diferente de 0 por separado.
- Sin embargo, el F nos dice que al menos uno de ellos sí lo es. ¿Por qué?
- Las variables *hrunsyr* y *rbisyr* están muy correlacionadas y esta multicolinealidad dificulta descubrir el efecto parcial de cada variable (dejando la otra fija). Esto se refleja en altas varianzas de los estimadores y bajos estadísticos t individuales.
- Recuerden que si tengo mucha correlación entre dos variables, la varianza de sus estimadores aumenta, haciendo más fácil no rechazar la nula.
- Sin embargo, el F -test al considerarlas juntas, no tiene ese problema y por eso es bueno para probar la exclusión de un conjunto de variables.
- Por ejemplo, suponga que quieren ver si el desempeño de una empresa afecta sueldos de CEOs. Hay muchas medidas para medir desempeño y seguramente están correlacionadas (e.g., profits, ventas, etc.). Entonces puede emplearse una prueba F para determinar si, como grupo, las variables de desempeño de la empresa afectan el sueldo.



Caso particular: Prueba de significancia global

- Prueba de significación global.
- La hipótesis nula es que el modelo entero no explica y :

$$H_0 : \beta_1 = \cdots = \beta_k = 0$$

- En este caso, el modelo restringido es: $y = \beta_0 + u$.
- El valor de R_r^2 para el modelo restringido es cero. ¿Por qué?
- Entonces el estadístico

$$F = \frac{(R_{ur}^2 - R_r^2)}{(1 - R_{ur}^2)} \cdot \frac{n - k - 1}{k} \sim F(k, n - k - 1)$$

- se reduce a

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - k - 1}{k}$$

- donde R^2 es el valor obtenido en el modelo sin restringir.

