

Econometría ICS-294

Clase 12: Propiedades asintóticas

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Introducción

Pregunta clave: ¿Cómo se comporta el estimador de MCO cuando el tamaño de la muestra crece indefinidamente?

- El análisis asintótico nos permite estudiar el comportamiento del estimador en muestras grandes.
- Es útil para justificar inferencias cuando la normalidad exacta de los errores no se cumple.



Muestras finitas vs. muestras grandes

- Propiedades de muestras finitas: válidas para cualquier n , como la insesgadez bajo Gauss-Markov.
- Propiedades asintóticas: válidas cuando $n \rightarrow \infty$.
- Nos interesa estudiar el comportamiento de los estimadores cuando el tamaño de la muestra crece.



Supuestos para la consistencia de MCO

- 1) Linealidad en los parámetros.
- 2) Muestreo aleatorio.
- 3) No hay multicolinealidad perfecta.
- 4) Exogeneidad: $E[u|x_1, x_2, x_3, \dots, x_k] = 0$

Estos supuestos son los mismos del inesgamiento.

No asumimos que la distribución de los u es normal.



Un supuesto 4': exogeneidad débil

- Para la **consistencia** basta con

$$E(x_i' u_i) = 0 \quad (\text{no correlación / exogeneidad débil})$$

- Una manera de caracterizar el supuesto de media condicional cero, $E(u|x_1, \dots, x_k) = 0$ es que ninguna **función** de las variables explicativas está correlacionada con u . El supuesto 4' sólo requiere que ninguna x_j esté correlacionada con u .
- Consecuencia práctica: la **omisión de variables relevantes** correlacionadas con los regresores incluidos genera **inconsistencia** (no solo sesgo), y ese sesgo asintótico *no desaparece* al aumentar n .



¿Qué es la consistencia?

Un estimador es **consistente** si:

al aumentar el tamaño de la muestra, el estimador se aproxima al valor verdadero del parámetro:

$$\hat{\beta}_j^n \xrightarrow{p} \beta_j$$


- En términos probabilísticos: su distribución se concentra en torno al parámetro.
- A medida que el tamaño de la muestra aumenta ($n \rightarrow \infty$), la probabilidad de que el estimador esté muy cerca del parámetro se aproxima a 1. Es decir, los valores del estimador se agrupan cada vez más cerca del valor del parámetro conforme n crece.
- $Prob(|\hat{\beta}_j^n - \beta_j| > \epsilon) \rightarrow 0$ cuando $n \rightarrow \infty \quad \forall \epsilon$

Se escribe usando la notación **plim**: $\text{plim } \hat{\beta}_j^n = \beta_j$



Consistencia

Distribución de Beta_1 para distintos tamaños muestrales



Distribución normal asintótica

Definition

Una secuencia de variables aleatorias $\{Z_n\}$ tiene una **distribución normal estándar asintótica** si para todo z :

$$P(Z_n \leq z) \rightarrow \Phi(z) \quad \text{cuando } n \rightarrow \infty,$$

donde $\Phi(\cdot)$ es la función de distribución acumulada normal estándar. Se escribe

$$Z_n \rightsquigarrow \text{Normal}(0, 1).$$

- Base del **Teorema Central del Límite (TCL)**: la suma (estandarizada) de v.a.i.i.d. converge a una normal, sin importar la distribución original.



Normalidad asintótica de MCO

Bajo los supuestos de Gauss-Markov (sin requerir normalidad de u):

$$\sqrt{n}(\hat{\beta}_j - \beta_j) \sim \text{Normal}(0, \sigma^2 a_j^{-2})$$

En notación matricial:

$$\sqrt{n}(\hat{\beta} - \beta) \sim \text{Normal}(0, \sigma^2 A^{-1}), \quad A = E(x_i' x_i)$$

Interpretación: para n suficientemente grande, $\hat{\beta}$ se distribuye **aproximadamente** normal, aun si u no es normal.



Idea de la demostración (caso simple)

Se puede escribir:

$$\sqrt{n}(\hat{\beta}_1 - \beta_1) = (1/s_x^2) n^{-1/2} \sum_{i=1}^n (x_i - \bar{x}) u_i$$

1. Por LGN: $s_x^2 \xrightarrow{p} \sigma_x^2 = \text{Var}(x)$
2. $\{(x_i - \mu)u_i\}$ es i.i.d., media 0, varianza $\sigma^2 \sigma_x^2$ (bajo homocedasticidad)
3. Por el **TCL**: $n^{-1/2} \sum_i (x_i - \mu)u_i \sim \text{Normal}(0, \sigma^2 \sigma_x^2)$
4. El término $(\mu - \bar{x}) n^{-1/2} \sum_i u_i \xrightarrow{p} 0$ (no afecta la distribución límite)
 $\Rightarrow \sqrt{n}(\hat{\beta}_1 - \beta_1) \sim \text{Normal}(0, \sigma^2 / \sigma_x^2)$



Consecuencias prácticas

- Los estadísticos t y F tienen distribuciones **asintóticamente** t / χ^2 , incluso sin normalidad de u .
- Justifica el uso de inferencia estándar (IC, valores- p) en **muestras grandes**, aun si los errores no son normales.
- El **Multiplicador de Lagrange (LM)** y el **estadístico de Wald** se basan en estos mismos resultados de convergencia.
- Con heterocedasticidad, se reemplaza $\sigma^2 A^{-1}$ por una matriz de varianza-covarianza **robusta**:

$$\widehat{\text{Avar}}(\hat{\beta}) = (X'X)^{-1} \left(\sum_i \hat{u}_i^2 x_i' x_i \right) (X'X)^{-1}$$



Eficiencia asintótica de MCO (Teorema 5.3)

- Bajo los supuestos de Gauss-Markov **más** homocedasticidad, MCO no solo es MELI (Gauss-Markov) en muestra finita.
- Es también **asintóticamente eficiente** entre una clase amplia de estimadores (no solo lineales) que son consistentes bajo los mismos supuestos.
- Compara la matriz de varianza-covarianza asintótica de MCO con la de cualquier otro estimador consistente y asintóticamente normal: MCO tiene la menor varianza asintótica.



Resumen: muestra finita vs. asintótica

	Muestra finita	Asintótico
Propiedad	Insesgamiento	Consistencia
Requiere normalidad	Sí (para t , F exactas)	No
Supuesto clave	$E(u x) = 0$	$E(x'u) = 0$
Herramienta	Álgebra exacta	LGN + TCL
Resultado	$\hat{\beta} \sim \text{Normal exacta}$	$\sqrt{n}(\hat{\beta} - \beta) \dot{\sim} \text{Normal}$



Puntos clave para recordar

1. **Consistencia** $\neq$ inesgamiento: son propiedades distintas.
2. La **LGN** da consistencia; el **TCL** da normalidad asintótica.
3. MCO es consistente bajo supuestos **más débiles** que los necesarios para el inesgamiento.
4. La normalidad asintótica **no requiere** que u sea normal — solo tamaño de muestra grande.
5. Estos resultados justifican la inferencia estándar (t, F, IC) en la práctica aplicada.



Normalidad Asintótica

$$\hat{\beta} \xrightarrow{d} N(\beta, \Sigma) \quad (1)$$

donde $\Sigma = \sigma^2(X'X)^{-1}$.

La convergencia en distribución se debe al Teorema Central del Límite.

Implicaciones:

- Permite construir intervalos de confianza asintóticos.
- Justifica la inferencia estadística en muestras grandes aun cuando no se cumpla la normalidad de los errores.



Eficiencia Asintótica

Definición: Un estimador es asintóticamente eficiente si minimiza la varianza dentro de la clase de estimadores consistentes y asintóticamente normales.

- Bajo homocedasticidad, MCO es eficiente (Gauss-Markov).
- Bajo heterocedasticidad, MCO sigue siendo consistente, pero no eficiente (no se soluciona con muestra grande).



Importancia práctica

- En la práctica, siempre usamos muestras finitas.
- La consistencia indica que con suficientes datos, podemos acercarnos al valor verdadero.
- Granger (Nobel Economía 2003): *“Si usted no puede obtener un resultado correcto a medida que n tiende a infinito, es mejor que se dedique a otra cosa.”*



Aplicación en R: Bucle

► Colab

```

set.seed(123)                                #semilla
n_values <- c(30, 100, 500, 1000) # Distintos tamaños muestrales a analizar
R <- 1000                                     # Número de repeticiones (simulaciones) para cada n
betas_list <- list()                         # Lista para almacenar los estimadores beta_1 de cada n
for(n in n_values) {                         # Bucle por cada tamaño muestral
  betas <- numeric(R)                       # Vector para guardar las estimaciones
  for (i in 1:R) {
    x <- rnorm(n)                            # Generamos datos
    u <- rnorm(n)
    y <- 2 + 3*x + u                         # Modelo verdadero: beta_0=2, beta_1=3
    mod <- lm(y ~ x)                         # Ajustamos el modelo
    betas[i] <- coef(mod)[2]                 # Guardamos la pendiente estimada
  }
  betas_list[[as.character(n)]] <- betas # Almacenamos todas las betas de este n en la lista
}

```

