

Econometría ICS-294

Clase 17: Endogenidad y Variables Instrumentales

Francisco Alfaro Medina

Universidad Técnica Federico Santa María



Introducción

- En las clases pasadas vimos que cuando omitimos una variable x_2 que se correlaciona con x_1 , se viola el supuesto $E[u \mid x_1] = 0$ y nuestro estimador MCO estará sesgado.
- Cuando esto sucede, decimos que x_1 es **endógena (está correlacionada con el error)**.
- Una variable explicativa es endógena cuando su valor está parcialmente determinado dentro del sistema por relaciones que también afectan a la variable dependiente, lo que se manifiesta estadísticamente como correlación con el término de error.
- **¿Qué podemos hacer?**
- Método 1: variables instrumentales (IV).
- Método 2: mínimos cuadrados en 2 etapas (MC2E).



Causas de la endogeneidad


Generalmente observamos problemas de endogeneidad en una de estas tres situaciones:

1. Variables omitidas:
 - Son variables que están correlacionadas con las x (los regresores) pero no las podemos incluir por ser inobservables.
2. Simultaneidad: $x \rightarrow y$ y $y \rightarrow x$.
3. Error de medida en las x .



Endogeneidad

El problema de la endogeneidad:




$$E \left[\hat{\beta}_1^{MCO} \right] = \beta_1 + \delta_1 \beta_2$$

Con variable omitida.



Solución 1: Variables instrumentales

Una variable instrumental válida es una variable Z que se correlaciona con X , pero no con el error.



Formalmente, un instrumento es válido si cumple con **dos** supuestos clave:

1. **Relevancia:** $\text{Cov}(X, Z) \neq 0$. La variable Z afecta a X . Como observamos Z y X , este supuesto es testeable.
2. **Exogeneidad o restricción de exclusión:** $\text{Cov}(Z, U) = 0$.
 - El instrumento no se correlaciona con el error.
 - $E[Y | X] = E[Y | X, Z]$: el instrumento Z no afecta directamente a Y , sólo lo hace a través de su efecto en X .




Intuición

- La intuición es que X tiene dos componentes: una parte exógena y una parte endógena (que está correlacionada con u).
- El instrumento Z , al no estar correlacionado con u , nos permitirá utilizar solamente la parte exógena de X para identificar su efecto en Y .



Buenos y malos instrumentos

- ¿Cuál de los siguientes Z es un buen instrumento?



- Sólo el gráfico A muestra un instrumento válido, ya que cumple con:
 - 1) **Relevancia:** $\text{Cov}(z, x) \neq 0$ y 2) **Exogeneidad:** $\text{Cov}(z, u) = 0$.
- El caso B viola la exogeneidad porque el instrumento se correlaciona con el error ($\text{Cov}(z, u) \neq 0$).
- El caso C viola la relevancia. Si bien el instrumento no se correlaciona con el error, tampoco lo hace con X ($\text{Cov}(x, z) = 0$).



Ejemplos de variables endógenas e instrumentos en la literatura

■ Retornos de la educación:

$$\log(\text{salario})_i = \beta_0 + \beta_1 \text{educ}_i + u_i.$$

- Z : trimestre de nacimiento (Angrist y Krueger, 1991).
- Z : proximidad geográfica a una universidad (Card, 1995).

■ Efecto de las instituciones en el PIB per cápita:

$$\text{GDP}_{2015,i} = \beta_0 + \beta_1 \text{instituciones}_{2015,i} + u_i.$$

- Z : mortalidad por enfermedades en el país cuando llegaron los europeos siglos atrás (Acemoglu *et al.*, 2001).



Implementación del método IV

- Métodos para estimar $\hat{\beta}^{IV}$:
 1. Estimación por Variables Instrumentales (VI) *per se*.
 2. Mínimos Cuadrados en Dos Etapas (MC2E),



Estimación por Variables Instrumentales (VI)

- Consideremos el modelo de regresión simple:

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, \dots, N.$$

- Problema: $\text{Cov}(u_i, x_i) \neq 0$.
- Contamos con un instrumento z que cumple:
 1. $\text{Cov}(u_i, z_i) = 0$.
 2. $\text{Cov}(x_i, z_i) \neq 0$.
- Entonces:

$$\begin{aligned} \text{Cov}(y_i, z_i) &= \text{Cov}(\underbrace{\beta_0 + \beta_1 x_i + u_i}_{y_i}, z_i) \\ &= \underbrace{\text{Cov}(\beta_0, z_i)}_0 + \beta_1 \text{Cov}(x_i, z_i) + \underbrace{\text{Cov}(u_i, z_i)}_0 \\ &= \beta_1 \text{Cov}(x_i, z_i). \end{aligned}$$

- Despejando: $\beta_1 = \frac{\text{Cov}(y_i, z_i)}{\text{Cov}(x_i, z_i)}$.



Relación poblacional y análogo muestral

- La **identificación** del parámetro en este contexto significa que se puede escribir β_1 en términos de los momentos poblacionales que se pueden estimar mediante una muestra de datos.

$$\hat{\beta}_{VI} = \frac{S_{y_i, z_i}}{S_{x_i, z_i}} = \frac{\sum_{i=1}^N (y_i - \bar{y})(z_i - \bar{z})}{\sum_{i=1}^N (x_i - \bar{x})(z_i - \bar{z})}.$$

- Todo esto es observable, por lo que podemos estimarlo (R lo hace por ustedes).
- Además, si se cumplen los supuestos sobre el instrumento Z , el estimador es consistente:

$$\hat{\beta}_{VI} \xrightarrow{p} \beta.$$



Estimación con VI en modelos de regresión múltiple

- La estimación por IV se extiende fácilmente a modelos con múltiples regresores.
- Nos centraremos en el caso con un **único** regresor endógeno y varios controles exógenos, aunque es posible tener más de una variable endógena.

Estimación por VI con una endógena y varias exógenas

$$\ln(\text{salario}_i) = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{mujer}_i + u_i.$$

- Idea: usar las exógenas como sus propios instrumentos; la matriz Z incluirá (i) la constante; (ii) el instrumento para educ ; y (iii) mujer .
- Aplicamos la fórmula anterior:

$$\hat{\beta}_{VI} = (Z^T X)^{-1} Z^T Y,$$

donde Z es de $N \times k + 1$, X es de $N \times k + 1$, Y es de $N \times 1$ y $\hat{\beta}^{IV}$ de $k + 1 \times 1$.



Resumen

- Decimos que una variable es endógena cuando $\text{Cov}(u, x) \neq 0$.
- En presencia de endogeneidad se viola uno de los supuestos de Gauss–Markov, y $\hat{\beta}_{\text{MCO}}$ será:
 - Sesgado.
 - Inconsistente.
 - No eficiente.
- Existen tres fuentes habituales de endogeneidad en economía:
 1. Omisión de variables relevantes.
 2. Simultaneidad.
 3. Errores de medida.
- Para estimar de manera consistente necesitaremos un **instrumento**.
- Un instrumento válido es una tercera variable z que cumple:
 - **Exogeneidad:** $\text{Cov}(u, z) = 0$.
 - **Relevancia:** $\text{Cov}(x, z) \neq 0$.
- El método de IV permite estimar β de forma consistente.



Inferencia y estimación por Variables Instrumentales

- Al igual que MCO, VI es un método de estimación
 - Un método para obtener un estimador de nuestro parámetro de interés β
- Tal como con MCO, una vez obtenidas las estimaciones $\hat{\beta}_{VI}$ queremos hacer inferencia estadística sobre las mismas. Necesitamos errores estándar.
 - Ej. pruebas t de significación de los parámetros
- Tal como en MCO, vamos a asumir homoscedasticidad, ahora condicional en el instrumento z : $\text{Var}(u | z) = \sigma^2$



Inferencia y estimación por Variables Instrumentales

- Se puede demostrar que se puede estimar la varianza de $\hat{\beta}_{VI}$ como:

$$\text{Var}(\hat{\beta}_{VI}) = \frac{\hat{\sigma}^2}{\text{SST}_x R^2_{x,z}}$$

donde

- $\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2$
- $R^2_{x,z}$ es el R^2 de la regresión: $X_i = \alpha_0 + \alpha_1 Z_i + v$
- $\text{SST}_x = \sum_{i=1}^n (x_i - \bar{x})^2$ es la suma de cuadrados total de X .



Estimador para la varianza de las estimaciones por VI

- Noten que:

$$\text{Var}(\hat{\beta}_{VI}) = \frac{\hat{\sigma}^2}{\text{SST}_x R_{x,z}^2}$$

- Noto: Mientras más débil la relación entre x y su instrumento z , menor $R_{x,z}^2 \rightarrow$ mayor $\text{Var}(\hat{\beta}_{VI})$.
- I Modelo de Regresión Simple:

$$\text{Var}(\hat{\beta}_{MCO}) = \frac{\hat{\sigma}^2}{\text{SST}_x}$$

- Dado que $R_{x,z}^2 \leq 1$, la varianza de las estimaciones por VI será mayor o igual a la varianza de los estimadores MCO.
 - Mientras más fuerte la relación entre x y z , más se acercarán las varianzas.
 - Caso extremo: x es exógena, x es el instrumento de $x \rightarrow R_{x,z}^2 = 1 \rightarrow \text{Var}(\hat{\beta}_{VI}) = \text{Var}(\hat{\beta}_{MCO})$.



Estimación por mínimos cuadrados en dos etapas

- Otro método para estimar consistentemente los parámetros con instrumentos es el Mínimos Cuadrados en 2 etapas (MC2E). El coeficiente que obtenemos será el mismo.
- Comenzamos con el siguiente modelo donde estamos interesados en el efecto de x_1 en y_1 :

$$y_i = \beta_0 + \beta_1 x_{1i}(\text{endo}) + \beta_2 x_{2i}(\text{exog}) + u_i \quad \forall i = 1, \dots, N$$

Con:

- (I) $\text{Cov}(x_{1i}, u_i) \neq 0$,
 - (II) $\text{Cov}(x_{2i}, u_i) = 0$,
 - (III) $\text{Cov}(z_i, u_i) = 0$
- Por ejemplo:

$$\ln(\text{salario}_i) = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{mujer} + u_i$$

- Y podemos usar como instrumento de *educ* la distancia al establecimiento educativo más cercano.



MC2E - Etapa 1

Primera etapa: $Z \rightarrow X$ Regresamos la variable endógena sobre todas las exógenas incluido el instrumento

- **Paso 1:** Estimamos la siguiente ecuación por MCO.

$$x_{1i} = \beta_0 + \beta_1 z_i + \beta_2 x_{2i} + v_i \quad (1)$$

- **Paso 2:** Obtenemos los $\hat{\beta}$ y construimos el valor predicho de x_1 :

$$\hat{x}_{1i} = \hat{\beta}_0 + \hat{\beta}_1 z_i + \hat{\beta}_2 x_{2i} \quad (2)$$

- Noten que $\hat{x}_1$ es una función de z y x_2 que son variables exógenas. Por lo tanto, no correlaciona con el error (u). El instrumento permite quedarnos con la parte exógena de x .
- **Intuición:** $x_i = \hat{x}_i + \hat{v}_i$. Solo usamos la parte exógena: $\hat{x}_i$ y nos deshacemos de la endógena.
- **Paso 3:** Noten que durante este paso, se aprovecha para testear la relevancia del instrumento. Haciendo un test de $\hat{\beta}_1 \neq 0$.



MC2E - Etapa 2

Segunda etapa: $\hat{x} \rightarrow y$

- En la ecuación original, reemplazamos la variable endógena x_1 por la predicción de esta variable que obtuvimos en la primera etapa $\hat{x}_1$ (Ec.2).
- Nuestra ecuación original (Ec.1) la podemos escribir entonces:

$$y_i = \beta_0 + \beta_1 \hat{x}_{1i} + \beta_2 x_{2i} + u_i \quad (3)$$

- $\hat{x}_{1i}$ es exógena, ya que es una combinación lineal de variables exógenas (Ec.2).
- Ahora, ¡podemos estimar Ec.3 por MCO!

$$\hat{\beta}_{MC2E} = (\hat{X}^T \hat{X})^{-1} \hat{X}^T Y \quad (4)$$

- Con $\hat{X} = \begin{bmatrix} 1 & \hat{x}_{1,1} & x_{2,1} \\ 1 & \hat{x}_{1,2} & x_{2,2} \\ \vdots & \vdots & \vdots \\ 1 & \hat{x}_{1,n} & x_{2,n} \end{bmatrix}$

- El $\hat{\beta}_1$ hallado de esta manera se conoce como $\hat{\beta}_{1,MC2E}$.



Conclusiones

- Vimos dos métodos para estimar consistentemente los parámetros cuando el regresor es endógeno y contamos con un instrumento válido:
 - VI
 - MC2E
- En el Modelo de Regresión Simple (MRS), con un solo instrumento, ambos métodos nos darán las mismas estimaciones puntuales y los mismos errores estándar.
- Los resultados serán distintos cuando tengamos más de un instrumento para la variable endógena.
- Estimar por estos métodos nos asegura la consistencia de las estimaciones siempre que los instrumentos sean válidos.
- Pero pagaremos el precio de menos precisión en esas estimaciones (errores estándar más grandes que en MCO).

