



Taller 1: Avance preliminar

Econometría ICS-294

II Semestre 2026

Profesor: Francisco Alfaro Medina

Objetivo: construir la primera mitad del proyecto aplicado utilizando la base de datos `wage1` del paquete `wooldridge`. Este taller corresponde al avance preliminar descrito en las instrucciones del trabajo.

Instrucciones:

- El trabajo se realizará en los grupos definidos para el proyecto.
- Utilice R en Google Colab y entregue el notebook junto con una versión exportada a PDF o HTML.
- Incluya el código utilizado, sus resultados y una breve explicación de cada procedimiento. El análisis debe ser reproducible.
- Use como guía el notebook `colab/regresion_wage_inferencia.ipynb`, pero redacte sus propias respuestas e interpretaciones.

1. Preguntas

Todas las respuestas deben referirse a la base `wage1`. En el notebook, cargue la base mediante `data('wage1', package = 'wooldridge')` y construya `lwage = log(wage)` si esta variable no estuviera disponible.

I. Conocimiento y calidad de la base de datos

1. Cargue la base y describa su estructura.
 - (a) Indique el número de observaciones y variables.
 - (b) Presente una tabla con el nombre, tipo y descripción económica de las variables que utilizará en el proyecto.
 - (c) Identifique cuáles variables serán la dependiente y las explicativas principales. Justifique esta elección en función de una pregunta económica.
2. Realice una auditoría básica de calidad de los datos.
 - (a) Reporte el número de valores faltantes por variable y el número de filas incompletas.
 - (b) Verifique si existen filas duplicadas.
 - (c) Revise los rangos y valores atípicos evidentes de `wage`, `educ`, `exper` y `tenure`.
 - (d) Explique si es necesario eliminar o transformar observaciones. Toda decisión de limpieza debe quedar documentada y justificada.

II. Descripción estadística y visualización

3. Construya una tabla de estadística descriptiva para las variables clave. Para cada variable numérica reporte, al menos, el tamaño muestral, media, desviación estándar, mínimo, percentil 25, mediana, percentil 75 y máximo.
 - (a) Incluya **wage**, **lwage**, **educ**, **exper** y **tenure**.
 - (b) Para **female**, **married** y **nonwhite**, presente frecuencias y porcentajes para los valores cero y uno.
 - (c) Interprete al menos tres resultados de la tabla y comente qué variables presentan mayor dispersión.
4. Elabore gráficos descriptivos con títulos, ejes y unidades claramente identificados.
 - (a) Construya histogramas de **wage** y **lwage**. Compare sus formas y explique por qué puede ser conveniente trabajar con el logaritmo del salario.
 - (b) Construya un boxplot de **lwage** según **female** y otro según **married**. Describa las diferencias visibles.
 - (c) Construya un gráfico de dispersión entre **educ** y **lwage**, incluyendo una recta de ajuste lineal.
 - (d) Construya al menos un gráfico adicional que ayude a estudiar la relación entre salario y experiencia o antigüedad. Explique qué patrón espera encontrar.

III. Pregunta de investigación y modelo propuesto

5. Formule la pregunta económica que guiará el proyecto.
 - (a) Escriba al menos dos hipótesis económicas verificables sobre el salario por hora. Indique el signo esperado de cada efecto.
 - (b) Señale cuál de sus hipótesis corresponde a un efecto individual y cuál requiere considerar varias variables simultáneamente.
 - (c) Explique por qué una relación observada en los datos no implica, por sí sola, un efecto causal.
6. Especifique el modelo de regresión poblacional que utilizará en el informe final. Considere como punto de partida:

$$\log(\text{wage}_i) = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_i + \beta_3 \text{tenure}_i + u_i.$$

- (a) Explique la elección de **lwage** como variable dependiente.
 - (b) Justifique la inclusión de **educ**, **exper** y **tenure**. Discuta si incluiría también **female** o **married** y por qué.
 - (c) Interprete económicamente cada coeficiente del modelo propuesto antes de estimarlo.
 - (d) Escriba una segunda especificación razonable, por ejemplo una que incluya una variable dummy o un término cuadrático para la experiencia. Explique qué hipótesis adicional permitiría estudiar.
7. Entregue un breve avance escrito que sintetice sus decisiones. Debe incluir: descripción de la base, tabla descriptiva, gráficos principales, pregunta de investigación, hipótesis, justificación de variables y los modelos poblacionales propuestos.

2. Formulario

- Media y desviación estándar muestral:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

- Transformación logarítmica:

$$\text{lwage}_i = \log(\text{wage}_i).$$

En un modelo log-nivel, un aumento de una unidad en una variable explicativa se asocia aproximadamente con un cambio de $100\beta_j$ por ciento en el salario.

- Modelo lineal poblacional:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + u_i.$$

- Comandos útiles en R: `dim()`, `str()`, `summary()`, `is.na()`, `duplicated()`, `mean()`, `sd()`, `quantile()`, `hist()`, `boxplot()` y `ggplot()`.